Notatki Systemy Operacyjne

Piotr Kotynia

14 czerwca 2022

Notatki studenckie zrealizowane na podstawie wykładów mgr inż. Pawła Sobótki uzupełnione o wiedzę ze slajdów, manuala, internetu i własną interpretację na przedmiot Systemy Operacyjne 1. Większa część notatek to opisy teorytyczne bez dokładnych opisów funkcji. W tym celu stworzyłem na końcu cheatsheet, który również nie jest kompletnym opisem zachowania funkcji, ale może pomóc w przypomnieniu lub wstępnym zrozumieniu funkcji lub struktury. Ostatecznie żeby zrozumieć dokładnie funkcję lub mechanizm i tak polecam przeczytać manuala. Notatki mogą być niekompletne, potencjalnie zawierać błędy i niepoprawne uproszczenia.

Spis treści

Część I

Systemy Operacyjne 1

1 Systemy operacyjne i komputerowe - wstęp

1.1 System operacyjny, a system komputerowy

1.1.1 Co to jest system operacyjny?

- Program pośredniczący między użytkownikiem i komputerem
- Dystrybutor zasobów - przydziela zasoby systemu i zarządza nimi
- Program sterujący - kontroluje wykonanie programów użytkownika oraz pracę urządzeń wejścia/wyjścia.
- **Jądro**(kernel) - jedyny program działający przez cały czas
- Podstawowe oprogramowanie systemu komputerowego, które pozwala
  1. wykonywać programy użytkownika i ułatwiać rozwiązywanie powstających problemów
  2. uczynić system komputerowy wygodnym w używaniu
  3. wykorzystać sprzęt jak najbardziej efektywnie
  4. Zarządzać sprzętowymi i programowymi zasobami systemu komputerowego
  5. Przekształcać maszyny rzeczywistej w maszynę wirtualną o cechach wymaganych przez przyjęty tryb przetwarzania

1.1.2 Składowe systemu komputerowego

Sprzęt (hardware) – dostarcza podstawowych zasobów systemowi (procesor, pamięć, urządzenia wejścia/wyjścia).

System operacyjny – zarządza i koordynuje wykorzystanie sprzętu przez różnorodne programy aplikacyjne użytkowników.

Programy aplikacyjne – określają w jaki sposób należy użyć zasobów systemu dla rozwiązania zadań określonych przez użytkownika (kompilatory, systemy baz danych, gry, programy biurowe).

Użytkownicy – ludzie, maszyny, inne komputery.

1.1.3 Tryby pracy systemu komputerowego

Pośredni – wsadowy (offline, batch) zadania od poszczególnych użytkowników gromadzone są na nośniku jako wsad i wykonywane jedno po drugim w określonej kolejności. Brak wielozadaniowości. Dalej używane np. dla dużych obliczeń.

Bezpośredni – interakcyjny (on-line) symuluje wykonywanie wielu zadań jednocześnie (każdy PC, system z short-time schedulerem). Procesor jest przełączany pomiędzy kilkoma zadaniami, które są przechowywane w pamięci operacyjnej i na dysku.

W czasie rzeczywistym [1] – (real-time) Mają dobrze określone, stałe ograniczenia czasowe odpowiedzi na zewnętrzny bodziec.

System rygorystyczny (Hard RT system) Posiadają gwarantowane, nieprzekraczalne ograniczenia czasowe. Sztywne gwarancje czasowe eliminują konstrukcje zapewniające zmienność czasu realizacji, redukując w ten sposób koszty. Stosowane przede między innymi w systemach bezpieczeństwa (lotnictwo, szlabany, linie produkcyjne).

System łagodny (Soft RT system) Wersja łagodna, posiada limity czasu, ale pod pewnymi warunkami mogą być przekroczone. Wykorzystywane głównie w multimediach (np. VR).

1.2 Zadania systemów operacyjnych

Efektywne zarządzanie zasobami systemu komputerowego

- Przydział i odzyskiwanie zasobów
- Planowanie dostępu do zasobów
- Ochrona i autoryzacja dostępu do zasobów

[1] W tym kursie będzie jedynie zmianka o systemach RT, jest to bardzo rozbudowana dziedzina

- Rozliczanie użytkowników z wykorzystania zasobów
- Obsługa błędów

Zasoby systemu komputerowego

- Procesor(y), rdzenie
- Pamięć i inne urządzenia systemu komputerowego
- Informacja przchowywana w systemie

1.3 Działanie systemu komputerowego

Urządzenia wejścia/wyjścia i procesor mogą pracować współbieżnie, współzawodnicząc w dostępie do pamięci. **Sterownik urządzenia** (device controller) zarządza urządzeniami określonego typu i nadzoruje operacje wejścia/wyjścia pomiędzy urządzeniem, a lokalnym buforem sterownika urządzenia. Sterownik urządzenia powiadamia procesor o zakończeniu operacji wejścia/wyjścia za pomocą przerwania (interrupt).

1.3.1 Przerwania

Co to jest przerwanie? Przerwanie to zdarzenie, które powoduje, że potok przetwarzania procesora (wykonywanie instrukcji) jest przerywany i sterowanie przekazane jest do procedury obsługi przerwań (interrupt handler), czyli funkcji zaimplementowanej w kernelu). Adresy różnych interrupt handlerów znajdują się w wektorze przerwań (interrupt vector). Gdy jakiś proces jest przerywany, architektura zwykle blokuje przychodzenie nowych przerwań, choć są wyjątki.

Pułapka (trap) – innaczej wyjątek. Jest rodzajem przerwania generowanym programowo dla sygnalizacji błędu (np. dzielenia przez zero) bądź żądania realizacji zamówienia, wymagającego obsłużenia przez system operacyjny.

Obsługa przerwań System operacyjny zachowuje stan procesora (rejestry, licznik rozkazów). W wirtualnym pliku /proc/interrupts możemy odczytać statystyki przerwań w systemie

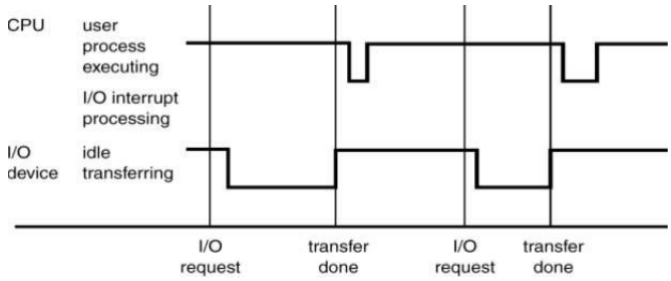

Rysunek 1: Uproszczony model obsługi przerwania przez CPU

1.3.2 Obsługa wejścia/wyjścia

Są dwa rodzaje obsługi:

Synchroniczna operacja wejścia/wyjścia Proces, który chce wykonać operacje wejścia wyjścia będzie czekał po wysłaniu prośby o wywołanie systemowe aż dostanie odpowiedź zwrotną. W tym czasie nie będzie wykonywał żadnych operacji.

Asynchroniczna operacja wejścia/wyjścia Proces, który wykonuje operacje wejścia wyjścia natychmiast po wysłaniu prośby, dostaje sterowanie z powrotem. W trakcie wykonywania operacji jest w stanie wykonywać dalej różne czynności. Przykład: API drivera karty graficznej otrzymuje request wyrenderowania klatki, a w tym czasie procesor jest wolny i może przygotować informacje do wyrenderowania następnej klatki.

2 Procesy

2.1 Koncepcja procesu

Proces – (zadanie) wykonujący się program. Procesy są rozróżniane za pomocą identyfikatorów procesów **(PID - process identifier)**, które są liczbami całkowitymi. Jeden program może tworzyć wiele procesów.

2.1.1 Składowe procesu

- Kod (text section) – licznik rozkazów i rejestry procesora

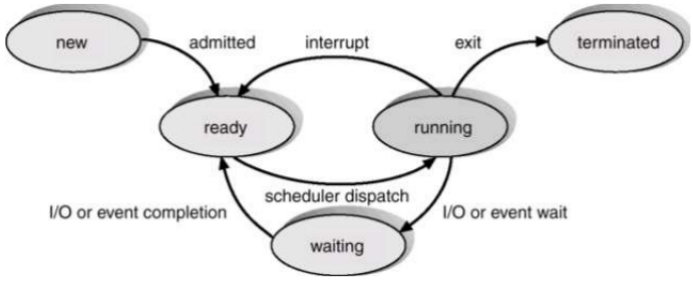

Rysunek 2: Diagram stanu procesów. Scheduler przypisuje procesowi stan running, proces może sam się zakończyć (exit), być wywłaszczony przez przerwanie (interrupt) lub samemu wejść w stan oczekiwania na operacje wejścia wyjścia (waiting)

- Stos (stack) – zawiera tymczasowe dane: parametry wywołania funkcji, zmienne lokalne (automatyczne)
- Sekcja danych – zawiera zmienne globalne i statyczne
- Sterta (heap) – zawiera dane przydzielane dynamicznie

2.1.2 Stan procesu

- Nowy (*new*) – proces został utworzony
- Aktywny (running) – są wykonywane instrukcje procesu
- Oczekujący (waiting) – proces czeka na wystąpienie jakiegoś zdarzenia
- Gotowy (ready) – proces czeka na przydział procesora
- Zakończony (terminated) – proces zakończył działanie

2.1.3 Blok kontrolny procesu (PCB)

Jest to tak naprawdę struktura w C, która zawiera informacje na temat procesu, implementacja znajduje się w */include/linux/sched.h* (polecam przeczytać.) Informacje zawarte w bloku kontrolnym procesu (process control block - PCB):

- stan procesu
- licznik rozkazów

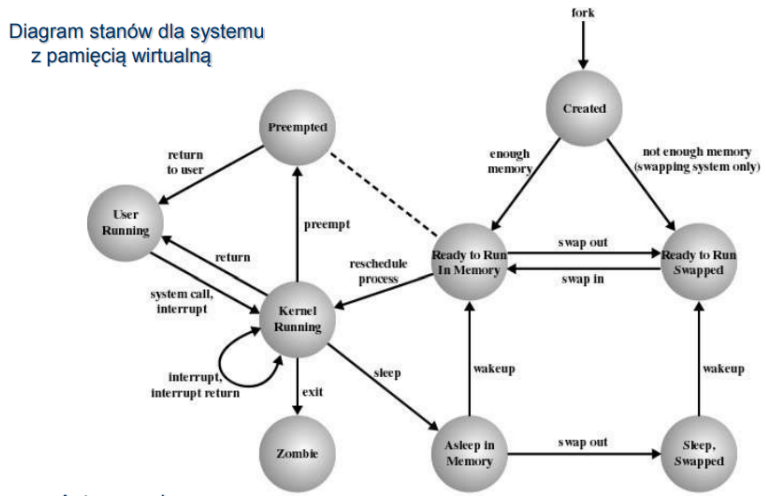

Rysunek 3: Rozbudowany diagram z pamięcią wirtualną. Istotna cecha – swap in / swap out - operacja zapisania danych z procesu do pamięci trwałej, używana zwykle przy niedoborach pamięci operacyjnej

- rejestry procesora
- informacje o planowaniu przydziału procesora
- informacje o zarządzaniu pamięcią
- informacje do rozliczeń
- informacje o stanie wejścia/wyjścia

2.1.4 Przełączanie procesora między procesami

Kernel zapisuje Przyczyny przerwania wykonania procesu:

- przerwanie zegarowe
- przerwania od urządzeń
- wywołanie f. systemowej
- wystąpienie pułapki

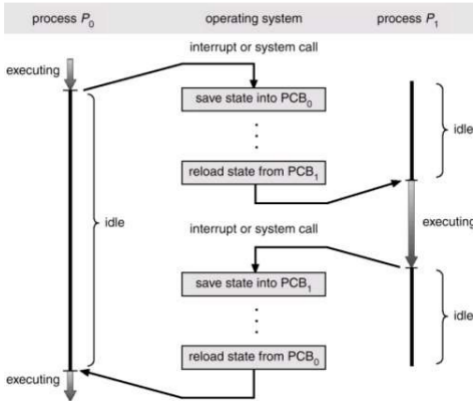

Rysunek 4: Schemat zamiany obsługiwanego procesu nazywany **zmianą kontekstu**. Zajmuje się tym scheduler (pol. planista, dyspozytor). W momencie kiedy scheduler ładuje stan procesu do rejestrów procesora to również konfiguruje hardwareowy timer, który po pewnym czasie (w windowsie 16ms) wywoła przerwanie, wtedy scheduler będzie mógł podjąć decyzje czy ponownie zmienić kontekst

2.2 Planowanie procesów

2.2.1 Kolejki planowania procesów

Procesy w postaci struktur PCB są umieszczane w kolejkach, które obsługuje scheduler. Przykłady kolejek:

- Kolejka zadań (job queue) – zawiera wszystkie zadania w systemie.
- Kolejka zadań gotowych (ready queue) – zawiera wszystkie procesy gotowe do działania (w pamięci operacyjnej)
- Kolejki do urządzeń (device queues) – listy procesów oczekujących na obsługę przez konkretne urządzenia

2.3 Działania na procesach

2.3.1 Tworzenie procesu

Procesy macierzyste (parent processes) tworzą procesy **potomne** (children), które też tworzą podprocesy. W rezultacie powstaje **drzewo procesów**.

Nowe procesy są tworzone za pomocją funkcji systemowej *fork()*, kopiuje ona całą przestrzeń adresową procesu, w którym wywołujemy funkcję. Zwraca: 0 dla procesu dziecka, PID procesu dziecka dla rodzica i -1 dla rodzica gdy nie można było utworzyć procesu dziecka. Uwaga: nigdy nie można przewidzieć, który proces zacznie się wykonywać pierwszy po wykonaniu fork().

Przykładowe polecenia/funkcje do zarządzania procesami:

- *ps* – wypisuje wszystkie procesy w systemie
- *pstree* – wypisuje drzewo procesów
- *getpid()* – zwraca PID procesu
- *getppid()* – zwraca PID rodzica
- *wait(int *stat_loc)* – w spobób synchroniczny oczekuje na zakończenie dowolnego procesu dziecka, jeśli się powiedzie zwraca PID dziecka. Opcjonalnie jeśli podamy stat_loc, zapisze tam status wyjściowy procesu dziecka.
- *waitpid(int *stat_loc, int options)* – wait tylko że inny

2.3.2 Planiści (schedulery)

Podział procesów:

- **ograniczone przez wejście wyjście** – spędzające dużo więcej czasu na wykonywanie operacji wejścia/wyjścia niż na obliczenia (wiele krótkich faz procesora)
- **ograniczone przez dostęp do procesora** – sporadycznie generujące zamówienia na operacje wejścia/wyjścia (nieliczne ale długie fazy procesora)

Rodzaje schedulerów (planistów) :

- **krótkoterminowy** – short-term scheduler/CPU scheduler. Wybiera do wykonania jeden z procesów gotowych i przydziela mu procesor. Podejmuje działanie bardzo często (n.p. co 100ms), więc musi działać szybko.
- **długoterminowy** – long-term scheduler/job scheduler. Wybiera procesy do kolejki procesów gotowych, wywoływany dosyć rzadko (co sekundy, minuty), więc może działać powoli. Kontroluje stopień **wieloprogramowości**. Usiłuje realizować dobrą mieszankę procesów. Nie wszystkie systemy operacyjne mają planistę długoterminowego.

2.3.3 Kończenie procesu

Proces za pomocą funkcji *exit()* prosi aby system operacyjny go zakończył. Kod wyjścia jest przekazywany do procesu macierzystego przez funkcje *wait()*. Proces, na którego rodzic nie "poczekał" funkcją *wait()* to **zombie**.

Proces, którego rodzic zakończył działanie (np. exit()), nie czekając aż procesy dzieci się zakończą, to **sierota** (orphant). Procesy sieroty adoptuje główny proces - **init** o PID 1. [2]

Proces macierzysty może spowodować zakończenie innego procesu (zazwyczaj potomka) za pomocą funkcji systemowej *kill()*

2.4 Środowisko wykonania procesu

Częścią środowiska wykonania procesu UNIX są **zmienne środowiskowe** (environment variables) w postaci: nazwa=wartość. Każdy proces ma swój zestaw zmiennych środowiskowych i **zawsze** mają formę **słownika**: lista w postaci klucz - wartość (string,string). W katalogu */proc* system zakłada podkatalogi z wirtualnymi plikami(nie są fizycznie plikami) odpowiadające informacjom dla każdego procesu. Np. w **environ** są zmienne środowiskowe (ale tylko w momencie początkowym uruchomienia procesu).

Często spotykane zmienne środowiskowe:

- **PATH** - lista ścieżek dostępu do plików wykonywalnych realizujących polecenia powłoki
- **HOME** - katalog macierzysty użytkownika
- **PWD** - aktualny katalog
- **PS1,PS2** - pierwszy i drugi tekst zachęty
- **TERM** - nazwa (typ, model) używanego terminala
- **SHELL** - używana powłoka
- **LOGNAME** -nazwa użytkownika
- **RANDOM** - liczba losowa
- **EDITOR** - edytor użytkownika
- **PPID** - nr procesu rodzicielskiego

[2] W niektórych systemach zamiast procesu init występuje proces **systemd**

Zmienne środowiskowe są dziedziczone przez proces potomny przy *fork()* i definiowane na nowo przy *execve() i execlve()*

Do nadawania wartości zmiennym środowiskowym w powłoce bash służy *name=value; export name*[3]

Aby nadawać wartości zmiennym środowiskowym w programie należy zdefiniować, a następnie modyfikować *extern char **environ*. Funkcje: *getenv(), putenv(), unsetenv() itp.* służą do przystępnej modyfikacji zmiennej environ (zalecane przeczytać manuala).

3 Interfejs systemu plików, strumieniowe wejście/wyjście

3.1 Koncepcja pliku

Plik to logiczna jednostka magazynowania informacji. W systemach UNIX jest to ZAWSZE jedynie tablica bajtów - nic ponad to.

Atrybuty plików:

- **Nazwa** – jedyna informacja przechowywana w postaci czytelnej bezpośrednio przez człowieka
- **Typ** – wymagany przez niektóre systemy operacyjne (dla interpretacji zawartości). Typ pliku może być rozpoznawany przez system, użytkownika bądź aplikację
- **Położenia** – wskaźnik do urządzenia i położenia pliku na tym urządzeniu
- **Rozmiar** – bieżący rozmiar pliku
- **Ochrona** – informacje służące do sprawdzania, kto może plik czytać, zapisywać, wykonywać
- **Czas, data, id użytkownika** – dane służące do ochrony, bezpieczeństwa i doglądania użycia plików

3.1.1 Operacje plikowe

- Create – tworzenie pliku

[3]Samo nadanie name=value nie wystarczy, ponieważ zmieni on tylko zmienną w obrębie procesu, aby wprowadzić ją do środowiska i przekazać do procesu potomnego trzeba go eksportować

- write – zapisywanie do pliku
- read – czytanie z pliku
- file seek – zmiana bieżącej pozycji w pliku
- delete – usuwanie pliku (bądź jego dowiązania do pozycji katalogowej; znaczenie bywa różne)
- truncate – skracanie pliku
- fd=open(Fi) – znajduje w strukturze katalogowej dysku wpis pliku Fi i kopiuje zawartość tego wpisu do pamięci – jeśli pozwalają na to reguły dostępu dla danego procesu. Operacja tworzy nową sesję plikową. Deskryptor fd reprezentuje dostęp do pliku w ramach sesji plikowej.
- Close (fd) – przepisuje zawartość struktury opisującej sesję plikową, związaną z deskryptodem fd, z pamięci do struktury katalogowej pliku (Fi) na dysku.

3.1.2 Blokady dostępu do plików

Systemy operacyjne często udostępniają procesom możliwość zakładania czasowej blokady dostępu do części bądź całego pliku

Blokada obowiązkowa – jest wymuszana przez jądro. Założenie takiej blokady powoduje, że system odmawia realizacji dostępu innym procesom przy próbie dostępu. Wbrew pozorom raczej rzadko używana.

Blokada doradzana – nie jest wymuszana przez jądro. Proces może sprawdzić, czy blokada jest założna przez inny proces, ale respektowanie blokady zależy od programisty.

3.1.3 Otwarte pliki

System utrzymuje w pamięci operacyjnej szereg struktur danych służących do obsługi otwartych plików:

- Wskaźnik bieżącej pozycji, indywidualny dla każdej sesji plikowej
- Licznik otwarć pliku – pozwalający na usunięcie wpisu pliku z tablicy otwartych plików, gdy licznik osiąga wartość 0

- Kopia informacji pozwalającej na odszukanie zawartości pliku na urządzeniu fizycznym
- Struktura informująca o prawach dostępu do pliku

Sesja plikowa – ciąg operacji na pliku pomiędzy otwarciem, a zamknięciem dostępu do pliku. Sesja jest skojarzona z deskryptorem pliku, stanowi on identyfikator sesji plikowej.

3.2 Struktura katalogowa plików

3.2.1 Rodzaje struktur katalogowych

Istnieje kilka sposobów na organizowanie struktury katalogów, każdy z nich ma swoje wady i zalety:

- **Katalog jednopoziomowy** – jeden katalog dla wszystkich użytkowników i wszystkich plików
- **Katalog dwupoziomowy** – Oddzielny katalog dla każdego użytkownika, ale wewnątrz katalogu użytkownika nie ma już żadnych katalogów
- **Katalog o strukturze drzewa** – Efektywne ułożenie plików pozwalające na hierarchizację
- **Katalog o strukturze acyklicznego grafu** – Usprawnienie katalogu o strukturze drzewa dodające możliwość dzielenia dostępu do plików i katalogów. Np. w dwóch katalogach może się znajdować plik, który jest tak naprawdę tym samym plikiem.

3.2.2 Katalog o strukturze acyklicznego grafu

Tworzenie dwócuh nazw (ścieżek) do tego samego pliku czy katalogu nazywamy *aliasingiem*. W UNIXie używamy mechanizmu hard/symlinków (polecenie ln) do tworzenia połączeń w systemie plików. Jeśli usuniemy ścieżke dostępu do pliku wraz z tym plikiem mamy problem – ine ścieżki dostępu przestają być ważne (nazywamy to *dangling pointers*.

Jak zagwarantować, że nie ma cykli?

- Zezwalać na dowiązania (link) do plików a nie do katalogów
- Odśmiecać system plików (garbage collection)

- Przy każdym tworzeniu dowiązania uruchamiać algorytm wykrywania cykli

3.2.3 Montowanie podsystemu plików

System plików musi być **montowany** w systemie operacyjnym zanim może być użyty - czyli wybieramy mu miejsce w grafie gdzie go podepniemy. Niezamontowany podsystem plików jest montowany w **punkcie montażu** (mount point). Poprzednia zawartość jest PRZESŁANIANA przez zamontowane poddrzewo plików - oznacza to, że gdy odepniemy nową zawartość, stara wróci na swoje miejsce. Zazwyczaj podsystem plików montuje się do pustego katalogu (taki korzeń). Za odpowiednio skonfigurowane podmontowanie wszystkich systemów plików odpowiedzialny jest kernel.

Polecenie *mount* wypisuje nam wszystkie podmontowane systemy plików.

3.2.4 Ochrona plików

Najczęściej uzależnia się dostęp do plików od identyfikacji użytkownika, bądź jego roli (role-based access controll). Najczęśniej stosuje się wykaz dostępów dla pliku (access list), zawierający id użytkowników i dozwolone rodzaje dostępu. Dla uproszczenia wprowadza się klasy (grupy) użytkowników.

Specjalnymi grupami w linuxie są **cgroups** (control groups). Jest to system przez który jądro ogranicza dostęp do zasobów (CPU, pamięć itp.) dla wybranych grup.

Tryby dostępu: read, write, execute (RWX). Tryb dostępu da się zakodować za pomocą liczby binarnej: R-4, W-2, E-1, czyli dostęp 7 oznacza wszystkie możliwe operacje. Dla pliku istnieją trzy klasy użytkowników i to dla nich ustalamy poszczególne rodzaje dostępu, są nimi: dostęp właściciela, dostęp grupy i dostęp publiczny.

Dostęp do pliku ustalamy za pomocą polecenia *chmod*.

3.3 Input/Output

3.3.1 Strumieniowe wejście/wyjście

Typ **FILE** jest definiowany przez STANDARD JĘZYKA, a nie przez system. Czyli API niskopoziomowe dla plików jest dostępne jeśli system udostępnia kompilator C zgodny ze standardem.

Deskryptor pliku (file descriptor) – unikalna, nieujemna liczba całkowita służąca do identyfikacji otwartego pliku. Maksymalna wartość i tymsamym maksymalna liczba otwartych plików dla procesora opisuje stała **OPEN_MAX**.

Strumień (stream) – Jest to logiczny objekt, który służy do komunikacji z otwartym plikiem. Maksymalną liczbę otwartych strumieni definiuje zmienna **FOPEN_MAX**. W standardzie ISO są one traktowane jak *FILE**, czyli wskaźniki do plików (file pointers). Do otwierania strumieni, służy np. funkcja *fopen()* zwracająca wskaźnik do obiektu kontrolującego strumień (FILE*).

3.3.2 Buforowanie strumieni

Strumienie mogą być:

- **Niebuforowane** (Unbuffered (_IONBF)) – znaki pisane lub czytane z takiego strumienia są przesyłane oddzielnie tak szybko jak to możliwe
- **Liniowo buforowane** (Line buffered (_IOLBF)) – znaki są przesyłane grupowo po odczytaniu znaku nowej linii (np. strumień terminala)
- **W pełni buforowane** (Fully buffered (_IOBF)) – bajty są wysyłane jako blok, kiedy zapełni się bufor strumienia (domyślnie większość nowo otwartych strumieni)

Dobry rozmiar bufora (*BUFSIZ*) jest podany w *¡stdio.h¿* (cokolwiek to znaczy).

Aby zmienić ustawienie ustawienie bufora, używamy funkcji *int setvbuf(FILE *stream, char *buf, int mode, size_t size)*. Np. *setvbuf(stdout, _IONBF, NULL, 0)* ustawi nam standardowy strumień wyjściowy na tryb niebuforowany, przez co następujący fragment kodu:

```
1 printf("Hello");
2 sleep(3);
3 printf("world\\n");
```

będzie wypisywał najpierw "Hello", potem czekał 3 sekundy, a następnie wypisywał "world
n". W przypadku domyślnego bufora, Tekst wypisał by się cały, dopóki bo drugim wywołaniu funkcji *printf*

Po co strumienie są domyślnie buforowane? Aby zaoszczędzić zasoby. Gdyby przy każdym wypisanym znaku system musiałby przechodzić w tryb jądra, generować przerwania, zmieniać kontekst, etc. Zamiast tego, znaki są wysyłane grupowo.

Funkcja *fflush()* służy do wysłania zbufurowanego outputu do pliku i czyści bufor.

W folderze */proc/[desktyptor procesu]/fd* znajdują się pliki (symlinki) odpowiadające otwartym strumieniom plików. Numery 0,1 i 2 to strumienie domyślne: stdin, stdout i stderr w konsoli.

3.3.3 Blokowanie strumieni, EOF i błędy

Strumienie można blokować np. po to by uniemożliwić dostęp do strumienia innym procesom, służą do tego funkcje: *flockfile(), ftrylockfile(), funlockfile()*

Strumienie wejściowe mogą się skończyć (np. plik się skończył), funkcja *feof()* przyjmuje strumień pliku i sprawdza czy wskaźnik końca pliku (end-of-file indicator) jest ustawiony na plik. Jeśli tak - zwraca niezerową wartość.

Funkcja *ferror()* działa jak funkcja *feof()*, ale dla wskaźnika błędu (error indicator). Sytuacja trudna do wygenerowania, dzieję się przy błędzie przy niskopoziomowej operacji np. zapisu na dysk.

3.3.4 Pozycja strumienia

Dla niektórych strumieni dozwolone jest "skakanie" po pozycjach, do tego służy funkcja *int fseek(FILE *stream, long int offset, int whence)*, gdzie ustawienie *whence* na wartość *SEEK_SET* pozwoli nam na ustalenie absolutnej pozycji. Generalnie bardzo ostrożnie bo raczej nie skaczemy po plikach tekstowych.

Funkcja *ftell()* pozwala nam na sprawdzenie na jakoiej pozycji znajduję się wskaźnik pliku.

3.3.5 Operacje na strumianiach I/O

Generalnie operacji jest mnóstwo i są bardzo rozbudowane, trzeba samodzielnie doczytać szczegóły manuala. Najczęściej używanymi są *fprintf() fscanff()*, ale są też inne. Przykłady:

- *int fgetc(FILE *stream)*
- *int getc(FILE *stream)*
- *int getchar(void)*
- *char * fgets(char *buf, int buflen, FILE *stream)*

- *int fputc(int c, FILE *stream)*
- *int putc(int c, FILE *stream)*
- *int fputs(const char *s, FILE *stream)*
- *int puts(const char *s)*
- *size_t fread(void *ptr,size_t size,size_t nitems,FILE *stream)*
- *size_t fwrite(void *ptr,size_t size,size_t nitems,FILE *stream)*

3.4 Manipulacje strumieniami katalogowymi

Do otwierania strumienia katalogów służy funkcja *opendir()* zwracająca strumień w postaci **DIR***. Do zamykania służy funkcja *closedir()*.

W standardzie POSIX pliki w katalogach są reprezentowane przez specjalne obiekty – **directory entry** zaimplementowane w postaci struktur *dirent*, które zawierają dwa pola: *ino_t d_ino* –numer i-węzła pliku *char d_name[]* – nazwa pliku. Funkcja *readdir()* służy do odczytywania *directory entry* ze strumienia katalogów. Ogólnie potrafi być mało bezpieczna bo w wielowątkowym programie, jeden wątek może nadpisać drugiemu strukturę dirent. Lepiej używać funkcji *readdir_r* – alokuje sam bufor, bierze adres i go wypełnia.

4 Niskopoziomowe operacje wejścia/wyjścia

Interfejs niskopoziomowy jest standaryzowany przec POSIX, a nie C. Umożliwia na wykonanie operacji niskopoziomowych takich jak *read() , write()*. Mamy pewne analogie do funkcji wysokopoziomowych C: zamiast strumieni standardowych: *stdin, stdout, stderr* mamy deskryptory: **STDIN_FILENO, STDOUT_FILENO, STDERR_FILENO**.

Mamy funkcję *fdopen()*, która zwraca nam strumień, więc możemy na nim operować funkcjami wysokopoziomowymi takimi jak *printf() czy scanf()*.

Funkcja *fileno()* zwraca nam deskryptor strumienia pliku

Zamiast *fopen* mamy *open()*, która otwiera istniejący plik w wybranym trybie. Przyjmuję ścieżke pliku w postaci ciągu znaków i **oflag**, która jest sumą logiczną stałych: **O_RDONLY, O_WRONLY, O_RDWR, O_TRUNC, O_NONBLOCK, O_NODELAY, O_APPEND** i zwraca **deskryptor pliku**.

Istotne flagi:

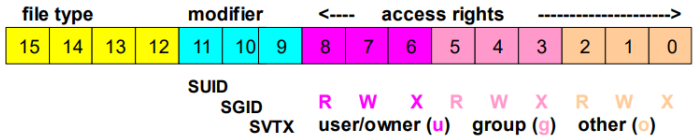

File attribute	Value (octal)	Value (symbolic)
FIFO	0010000	S_IFIFO
Special character device	0020000	S_IFCHR
Directory	0040000	S_IFDIR
Special block device	0050000	S_IFBLK
Ordinary file	0100000	S_IFREG
Symbolic link	0120000	S_IFLNK
Socket	0140000	S_IFSOCK

Rysunek 5: Diagram atrybutów plików: trochę nie czaje tabelki

O_CREAT – Tworzy nowy plik jeśli nie istnieje, albo otwiera istniejący

O_EXCL – Tworzy nowy plik, niepowodzenie gdy istnieje

Zamiast funkcji *fseek()* mamy funkcje *lseek()*, zamiast *fclose()* mamy *close()*.

Przykładowy program używający operacji niskopoziomowego wejścia/wyjścia

```
int ret;
char buf[10];
ret = write(STDOUT_FILENO, "Name? >", 7); //odpowiednik printf
ret = read(STDIN_FILENO, buf, sizeof(buf));    //scanf, obetnie
    jesli powyzej limitu
buf[ret] = '\0';  //wazne zeby dodac nullbyte
ret = write(STDOUT_FILENO, "Hello ", 6);
ret = write(STDOUT_FILENO, buf, strlen(buf)); //wypisuje bufor
```

4.1 O_NONBLOCK i pliki FIFO

Typ FIFO, inaczej plik łącza nazwanego, może być otwarty do zapisu i odczytu, proces który otwiera go do zapisu "wkłada" do niego bajty jak do kolejki, a z drugiego końca inny proces konsumuje te bajty przez czytanie. Umożliwia on komunikacje między procesami. Do stworzenia takiego pliku można użyć polecenia *mkfifo*. Flaga O_NONBLOCK służy głównie do otwierania plików FIFO.

Jeżeli nie jest ustawiona, czyli plik jest w trybie blokującym: gdy otwieramy

plik do odczytu, open() zablokuje aktualny potok i będzie czekał aż jakiś wątek otworzy plik do zapisu. Analogicznie tryb do zapisu będzie czekał aż plik zostanie otworzony z drugiej strony do odczytu.

W trybie nieblokującym: jeśli otworzymy do odczytu, open() powinien się wykonywać bez czekania i np. read() będzie się wykonywał nawet gdy nie ma czego odczytać. Jeśli otworzymy plik jedynie do zapisu, open() zwróci błąd jeśli żaden proces nie ma otwartego pliku do odczytu.

4.2 Struktury danych operacji I/O

Każdy proces ma swoją **tablice deskryptorów plików**, ale oprócz tego istnieje **tablica otwartych plików** kernela. Deskryptory plików w tablicy procesów są jedynie wskazaniami na miejsca w tablicy otwartych plików jądra. Z kolei wpisy w tablicy jądra są referencjami do **tablicy i-node'ów** w systemie plików.

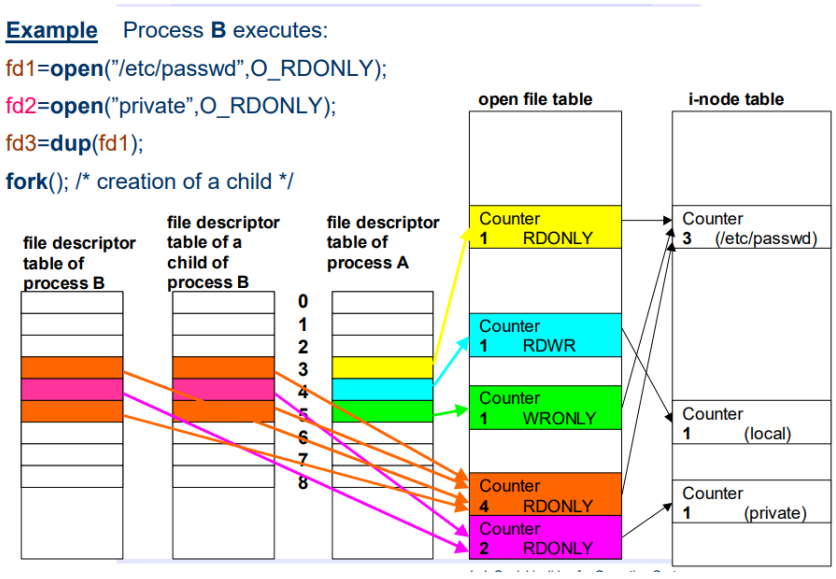

Rysunek 6: Co się dzieje? Każde otwarcie pliku, nawet jeśli odnosi się do tej samej ścieżki, jest nowym wpisem w tablicy otwartych plików. Aby 2 deskryptory wskazywały na to samo miejsce w tablicy należy użyć funkcji *dup()*, albo stworzyć nowy proces funkcją *fork()*.

Dlaczeg to jest istotne? Jeżeli proces otworzy kilka razy ten sam plik, deskryptory będą wskazywać na rózne elementy tablicy otwartych plików, czyli nie będą np. dzielić wskaźnika gdzie aktualnie znajdujemy się podczas czytania pliku. Jeśli chcemy aby deskryptory wskazywały na ten element tablicy, należy użyć funkcji *dup*, albo *dup2()* Proces dziecko dziedziczy deskryptory otwartych

plików od procesu rodzica, czyli wskazują na to samo miejsce w tablicy otwartych plików.

4.3 Synchroniczne operacje na plikach (do napisania)

5 Sygnały POSIX

Sygnał – mechanizm za pomocą którego proces lub wątek może się dowiedzieć o zdarzeniu, które wystąpiło w systemie. Do wysyłania sygnałów służy funkcja *kill()*. Długa i szczegółowa lista sygnałów i ich opis znajduje się pod man 7 signal.

Nr	Name	Meaning	Action
1	**SIGHUP**	Hangup	Exit
2	**SIGINT**	tty interrupt (typically: ^C)	Exit
9	**SIGKILL**	**Unconditional** process termination	Exit
11	**SIGSEGV**	Segmentation Fault	Core dump + exit
13	**SIGPIPE**	Broken Pipe	Exit
14	**SIGALRM**	Alarm Clock	Exit
15	**SIGTERM**	Software interrupt	Exit
	SIGUSR1,2	Two „user interrupts" (no pre-defining meaning)	Exit
	SIGCHLD	Child Status Changed	Ignore
	SIGCONT	Process to be continued	Continue
	SIGSTOP	**Unconditional** stop for a process	Stop
	SIGTSTP	Stop of a process via tty (typically: ^Z)	Stop
	SIGTTIN	Stopped (tty input)	Stop
	SIGTTOU	Stopped (tty output)	Stop

Rysunek 7: Lista najważniejszych sygnałów

Sygnały mogą być dostarczone do procesu albo do wątku (wątki będą później).

5.1 Obsługa sygnałów

Każdy sygnał ma zawsze zdefiniowany sposób w jaki zachowa się w odpowiedzi na każdy sygnał. Sygnał może być:

dostarczony (delivered) – jeśli odpowiednia akcja procesu jest wywołana: ignorowanie lub wywołanie **obsługi sygnału (signal handlers)** zdefiniowanej przez użytkownika albo domyślnej.

zaakceptowany (accepted) – jawne zaakceptowanie sygnału, np. kiedy sygnał jest zwrócony przez sigwait() - proces aktywnie czekał na sygnał, czyli sygnał został obsłużony **synchronicznie**.

zablokowany (blocked) – proces może zażyczyć sobie żeby sygnały, które otrzymuje oczekiwały na dostarczenie.

POSIX nie daje żadnej gwarancji co do tego ile razy proces otrzyma dany sygnał. Wysłany kilkukrotnie sygnał "skleja" się w jeden sygnał jeśli zostały wysłane w krótkim czasie. Nie jest zdefiniowana również kolejność w jakiej kilka różnych sygnałów zostanie obsłużona.

5.2 Własne procedury obsługi sygnałów

Funkcja do osbługi sygnału musi mieć następującą sygnature: *void handler_name(int signo)*. Mając taką funkcje możemy korzystać z metody API *sigaction()*, aby zdefiniować nową procedurę obsługi sygnału. Nie można przedefiniować procedury obsługi sygnału **SIGKILL**.

Proces potomny dziedziczy procedury obsługi sygnału.

5.3 Blokowanie sygnałów

Możemy w programie definiować, które sygnały będą przez proces blokowane. Struktura sygnałów, które będziemy blokować nazywa się *sigset_t*. Do zerowania tej struktury używamy *sigemptyset()*, dodajemy do zbioru sygnałów funkcją *sigaddset()* i konfigurujemy sygnały blokowane funkcją *sigprocmask()*.

6 Wątki i Muteksy

6.1 Podstawy wielowątkowości

Każdy proces ma dostęp do zasobów wymaganych żeby wykonać swoje zadanie. Może w tym celu użyć jednego lub więcej wątków. Dzielą one dostęp do

wspólnych zasobów procesu, ale mogą też posiadać własne zasoby. Do zalet wielowątkowości należy:

- responsywność – proces może się wykonywać nawet jeżeli jego część się zablokuje.
- dzielenie zasobów procesów – wątki dzielą zasoby procesy, to łatwiejsze niż współdzielona pamięć i przekazywanie wiadomości
- ekonomia – taniej jest przełączyć kontekst niż utworzyć nowy proces
- skalowalność – proces może wykorzystać wieloprocesorową architekturę aby wykonywać wątki współbieżnie

Wątki dzielą się na wątki **jądra**(WIndows, Solaris, Linux, itp.) i **użytkownika**(POSIX threads-Pthreads, Windows Threads, Java Threads). Itnieją różne modele mapujące wątki użytkownika na wątki jądra w sposób: many-1, 1-1 lub many-many.

My korzystamy z biblioteki *Pthreads* do zarządzania wątkami. Istnieje wiele problemów związanych z wprowadzeniem wielowątkowości, np. czy funkcja *fork()* powinna duplikować dany wątek czy wszystkie wątki? (POSIX definiuje, że powinniśmy duplikować tylko wątek wywołujący).

Każdy wątek ma swój własny prywatny stos. Wątki współdzielą przestrzeń adresową więc mają dostęp do swoich stosów nawzajem.

6.2 Mutexy

Mutex – obiekt synchronizujący, którego celem jest umożliwienie wielu wątkom serializować ich dostęp do współdzielonych danych. Nazwa pochodzi od mutual-exclusion – wzajemne wykluczanie. Wątek blokuje mutex i staje się jego właścicielem dopóki sam go nie odblokuje. Do blokowania służą funkcje: *pthread_mutex_lock()*(tryb blokujący) i *pthread_mutex_trylock()*(tryb nieblokujący). Do odblokowania: *pthread_mutex_unlock()*.

Mutex należy najpierw zainicjalizować funkcją *pthread_mutex_init()*, która wymaga również wskaźnika do struktury zawierającej atrybuty mutexu (ją również należy najpierw zainicjować specjalną funkcją). Póki co nie korzystamy z zaawansowanych funkcji więc "ustawiamy NULL i jest fajnie".

Mutex można też zainicjalizować specjalnym makrem mutex = PTHREAD_MUTEX_INITIALIZER.

Mutexów pod żadnym pozorem nie można przypisywać/kopiować!

Nieużywany mutex niszczymy funkcją *pthread_mutex_destroy()*

6.3 Anulowanie wątków

Anulowanie wątków to mechanizm, który pozwala jednemu wątkowi zakończyć wykonanie dowolnego innego. Każdy wątek ma skojarzone 2 specjalne atrybuty: **cancelability** – mówi nam o tym czy wogóle można anulować wątek oraz **cancelability type** – mówi o tym w jaki sposób nastąpi anulowanie. Do ustawiania tych atrybutów mamy funkcje pthread_setcancelstate() i pthread_setcanceltype().

- PTHREAD_CANCEL_DEFERRED - domyślna wartość, oznacza że wątek zakończy się przy anulowaniu dopiero gdy będzie w trakcie wykonywania jednej z funkcji, która znajduje się w liście *cancellation points*.
- PTHREAD_CANCEL_ASYNCHRONOUS – wątek zakończy się od razu po anulowaniu, być może nawet w trakcie wykonywania jakiejś funkcji maszynowej.

Funkcja pomocnicza, która po prostu jest cancellation point to *pthread_testcancel()*.

Jeśli przerwiemy funkcje i przez to nie zwróci ona wartości to zwrócony wskaźnik będzie miał wartość PTHREAD_CANCELED.

6.4 Cleanery

Przy anulowaniu wątków czasem chcemy aby zanim funkcja wyjdzie wykonała jakąś operacje. Służą do tego funkcje *pthread_cleanup_push()* i *pthread_cleanup_pop()*. Muszą one znajdować się na równym poziomie, pierwsza służy do ustawienia funkcji, która ma się wykonać przy anulowaniu, druga ustawia miejsce, w którym usuwamy ją z listy do wykonania i wykonujemy ją lub nie.

Część II

Systemy Operacyjne 2

7 Komunikacja międzyprocesowa (IPC)

7.1 Rodzaje komunikacji

Procesy dzielą się na dwa rodzaje ze względu na interakcje z innymi procesami:

- Procesy niezależne – nie mogą oddziaływać na inne procesy inne procesy nie mogą oddziaływać na nie.
- Procesy współpracujące – oddziałują wzajemnie na swoje wykonanie. System udostępnia takim procesom: współbieżne wykonanie oraz usługi synchronizacji i komunikacji.

Procesy współpracujące dzielą się ze względu na model komunikacji:

- Pamięć wspólna:
  1. Komunikacja pod kontrolą użytkownika
  2. Największa szybkość i oszczędność pamięciową komunikacji
  3. Problematyczna synchronizacja dostępu dodanych
  4. Zjawisko **data race** – dwa procesy "ścigają się" w dostępie do tego samego obszaru pamięci powodując liczne problemy np. nadpisując sobie nawzajem zmienne
- Przekazywanie komunikatów
  1. Komunikacja pod jądra systemu
  2. Prosta synchronizacja w realizowana przez system
  3. Brak problemów związanych z współdzieleniem tych samych obszarów pamięci
  4. Kopiowanie danych zmniejsza efektywność

Metody komunikacji międzyprocesowej (IPC):

- Sygnały

- Pliki współdzielone
- Muteksy
- Kod wyjścia procesu
- Strumienie standardowe
- Łącza zwykłe i nazwane (FIFO)
- Zestawy interfejsów POSIX np. UNIX System V IPC
- Gniazda (sockets)

7.2 Łącza

Łącze tworzy kanał komunikacji między dwoma procesami. Istnieją dwa rodzaje łączy:

- **Łącza zwykłe(anonimowe)** – Reprezentowane przez **pipe**. Po utworzeniu nie są widoczne przez inne procesy, ale dostęp do nich może być przekazany.
- **Łącza nazwane** – Reprezentowane przez **FIFO** mogą być udostępniane każdemu procesowi dzięki nazwie.

Przekazywanie danych jest na zasadzie producent-konsument. Producent pisze dane do jednego końca łącza, a konsument czyta je z drugiego.

7.2.1 Łącza anonimowe - pipe

Cechą łącza anonimowego jest to, że **nie jest widoczny w systemie plików**. Do utworzenia służy funkcja *pipe()*. Przyjmuje ona tablice dwóch integerów, i zapisuje do pierwszego deskryptor służący do odczytu, a do drugiego deskryptor do zapisu. Trzeba też jednak przekazać te deskryptory procesowi z którym chcemy się komunikować np. poprzez *fork()* – wtedy dziecko odziedziczy tablice deskryptorów, lub przez gniazda lokalne (później).

Mamy też wysokopoziomowy interfejs otwierania pipe, zwracający nam plik **FILE*. Służy do niego funkcja *popen()*. Cechy łącza anonimowego:

- Dostępne tylko poprzez deskryptory
- Brak wsparcia pozycjonowania – odczyt i zapis bez ustawiania pozycji ze skutkiem błędu **ESPIPE**

- Nie można pisać do zamkniętego łącza
- Dane w łączu to zlepek bajtów bez logicznego odseparowania
- Odczyt i zapis jest nierozdzielny (atomic) dla danych nie większych od **PIPE_BUF** czyli maksymalnej pojemności łącza. Gdy przekroczymy ten limit proces czeka aż inny proces nie odczyta tych bajtów z drugiej strony.

7.2.2 Łącza nazwane - FIFO

Co do zasady działania FIFO nie różni się od łącza anonimowego, za to jest widoczny w systemie plików. Do utworzenia FIFO służy funkcja *mkfifo()*. Przyjmująca ścieżkę i tryb praw dostępu do pliku.

Domyślnie otwieranie jest blokujące, czyli otwarte FIFO czeka na otworzenie drugiego końca. Można otworzyć nieblokująco koniec do odczytu, ale pod żadnym pozorem nie do zapisu, nie można pisać do pliku, z którego nic nie czyta.

7.2.3 Błędy i SIGPIPE

Prawidłowa obsługa błędów i sygnałów w przypadku łącz może być problematyczna, i trzeba wiedzieć o kilku rzeczach. Próba zapisu do zamkniętego łącza ustawia nam błąd **EPIPE** i wysyła do procesu sygnał **SIGPIPE**, który domyślnie zabija proces.

W przypadku nieblokującego zapisu danych rozmiaru co najwyżej **PIPE_BUF**: jeśli mamy wystarczająco dużo miejsca zapis się uda, jeśli nie to nie zapiszemy żadnych danych w łączu i otrzymamy błąd **EAGAIN**.

W przypadku nieblokującego zapisu danych większych od PIPE_BUF: jeśli przynajmniej jeden bajt może być zapisany - zapis się uda, jeśli nie to nie zapiszemy żadnych danych w łączu i otrzymamy **EAGAIN**.

W przypadku odczytu dla pustego łącza:

Jeśli żaden proces nie ma otwartego końca do zapisu, funkcja read() w obu trybach: blokującym i nieblokującym zwraca 0, czyli end-of-file.

Jeśli jakiś proces ma otwarty koniec do zapisu: w trybie blokującym wątek czeka aż pojawią się dane, w trybie nieblokującym *read()* zwraca -1 i ustawia errno na **EAGAIN**.

7.3 Kolejki komunikatów

Kolejki komunikatów rozwiązują problem, który ma łącze nienazwane w postaci *pipe*, czyli sklejania się wiadomości. Składają się z komunikatów, którym możemy nadać różne priorytety. Niezwiązane procesy mogą też swobodnie dostawać się do tej samej kolejki,

Kolejki mają trwałość w ramach systemu, czyli żyją do jego restartu lub jawnego usunięcia. W przypadku Linuxa kolejka jest widoczna w systemie plików, jest identyfikowana przez deskryptor kolejki (może być implementowany jako deskryptor pliku) i znajduje się ona w specjalnej, dedykowanej dla kolejek przestrzeni nazw. Wirtualne pliki kolejek są w folderze */dev/mqueue/* (katalog ma płaską strukture). Nie są one fizycznie obecne na dysku, ale są widoczne jako pliki analogicznie do procesów w katalogu */proc*. Atrybuty kolejki określa struktura **mq_attr** zawierająca:

- **mq_maxmsg** – maksymalna liczba wiadomości w kolejce, gdy przekroczona proces piszący się zablokuje
- **mq_msgsize** – maksymalna długość wiadomości
- **mq_flags** – 0 albo NON_BLOCK
- **mq_curmsgs** – aktualna liczba komunikatów

Przekazywanie komunikatów wielkości mniejszej niż max. dla kolejki jest niezawodne. Deskryptor kolejki jest zmienną typu **mqd_t** (czyli w sumie int).

Implementacja defniniuje też stałe określające cechy kolejki

- **MQ_PRIO_MAX** – maksymalny możliwy priorytet
- **MQ_OPEN_MAX** – maksymalna liczba kolejek otwartych przez jeden proces.

Parametry kolejki można zmieniać w */proc/sys/fs/mqueue*.

Do tworzenia/otwierania kolejki służy *mq_open()*, do zamykania *mq_close()* i kasowania *mq_unlink()*.

Do wysyłania komunikatów: *mq_send()* i *mq_timedsend()*, a do odbierania: *mq_receive()* i *mq_timedreceive()*.

Wersje z *timed* służą do ograniczenia czekania.

Do pobierania i ustawiania atrybutów kolejek służą: *mq_getattr()* i *mq_setattr()*.

Możemy też dla procesu ustawić opcję powiadamiania procesu o pojawieniu się wiadomości w konkretnej kolejce. Do wyboru jest powiadamianie przez sygnał lub przez wywołanie wątku, działa to analagicznie do asynchronicznego API I/O.

Służy do tego funkcja *mq_notify()*. W danym momencie tylko jeden proces może zasubskrybować powiadomienie dla konkretnej kolejki. Próba rejestracji powiadomienia gdy inny proces już to zrobił powinna się nie udać. Po każdym powiadomieniu trzeba odnowić subskrypcje ustawiając powiadomienie ponownie. Powiadomienie jest wywoływane tylko w momencie gdy kolejka jest pusta i nagle dostanie wiadomość.

7.4 Pamięć dzielona

Procesy moga się ze sobą komunikować poprzez dzielenie tej samej przestrzeni adresowej. Jest to trudne ze względów bezpieczeństwa i komunikacji, ale również bardzo szybkie.

7.4.1 Odwzorowanie plików w pamięci

Jednym ze sposobów jest bezpośrednie odwzorowanie części pliku w przestrzeń adresową procesu. Należy najpierw plik otworzyć, a następnie zmapować przestrzeń funkcją *mmap()*. Otrzymujemy w ten sposób wskaźnik, który odwołuje sie do zmapowanej pamięci. Następnie możemy tłumaczyć operacje wykonane na pliku w przestrzeni adresowej procesu na operacje dyskowe. Funkcja*mmap()* to bardzo obszerne narzędzie i my będziemy opisywać tylko część jej możliwości.

Możem zmapować pamięć w taki sposób żeby zmiany były widoczne dla innych procesów lub uczynić tak żeby proces miał swoją kopie pamięci pliku i zmiany będą dokonywane tylko na potrzeby danego procesu. Robimy to poprzez ustawienie parametru protect na **MAP_PRIVATE** – modyfikacja w pamięci zmapowanej nie jest zapisywana do pliku, lub **MAP_SHARED** – zapis do odwzorowanego obszaru spowoduje operacje dyskową modyfikującą plik.

Do takiej wymuszania zapisu zawartości obszaru pamięci odwzorowanego w trybie **MAP_SHARED** służy funkcja *msync()*, która w przypadku użycia flag **MS_SYNC** będzie to robiła w sposób synchroniczny (poczeka aż dane się zapiszą), lub **MS_ASYNC**, wtedy zrobi to asynchronicznie (nie poczeka).

7.4.2 Współdzielone segmenty pamięci

Procesy mogą również tworzyć segmenty pamięci, do których dostęp będą miały inne procesy. Funkcją *shm_open()* tworzymy połączenie między segmentem pamięci, a deskryptorem pliku. Otrzymany deskryptor, służy nam do odwzorowania segmentu na przestrzeń adresową procesu funkcją *mmap()* tak jakby to był zwykły plik. Każdy proces, który ma nazwę segmentu (i właściwe prawa) jest w stanie otworzyć go i zmapować w swojej przestrzeni adresowej.

Po otworzeniu segmentu należy określić jego rozmiar funkcją *ftruncate()* i odwzorować segment na przestrzeń adresową procesu funkcją *mmap()* z flagą **MAP_SHARED**. Po zakończeniu usunąć odwzorowanie funkcją *munmap()* – usuwa ona wszystkie odwzorowania adresów pamięci. Funkcja *shm_unlink()* usuwa podaną nazwę (bo segmenty pamięci dzielonej są rozpoznawane przez nazwy w systemie plików) segmentu pamięci dzielonej. Z racji tego można też używaż funkcji takich jak *fstat()*, *fchown()* lub *fchmod()* do modyfikacji praw dostępu, właściciela, UID, GID itp. tego segmentu.

7.4.3 System V

Istnieje również interfejs API IPC Systemu V. Jest to API **archaiczne** i nie będzie szeroko omawiane. Z tego powodu warto jedynie znać podstawy tego interfejsu. Do różnych mechanizmów Systemu V służyły specjalne obiekty i funkcje służące do tworzenia, sterowania i komunikacji z nimi. Przykładowo do tworzenia obiektu kolejek komunikatów służyła funkcja *msgget()*, a do wysyłania i odbierania wiadomości *msgsnd()* i *msgrcv()*.

Trwałość obiektów IPC Systemu V to **trwałość jądra** (kernel persistance), czyli obiekty istnieją do przeładowania systemu (restartu) lub jawnego usunięcia. Obiekty są globalne i pają swoje klucze identyfikujące. Do każdego obiektu IPC jądro przechowuje strukturę **ipc_perm**z prawami dostępu (UID i GID właściciela, twórcy, tryby dostępu, klucz, numer kolejny)

Jest tu również system pamięci dzielonej, gdzie do segmentu pamięci jest przydzielona struktura opisująca własności segmentu – prawa dostępu, rozmiar, PID twórcy, PID ostatniego użytkownika, liczba połączeń, czasy ostatniego dołączenia i połączenia i ostatnia zmiana struktury.

W skrócie: System V również implementował omówione wcześniej metody komunikacji międzyprocesowej, ale robił to trochę inaczej. Jeśli ktoś chciałby wiedzieć więcej trzeba czytać manuala albo googlować.

8 Synchronizacja

Problem współbieżności i metod synchronizacji był już poruszany wcześniej, ale jest na tyle rozbudowany, że wymaga dodatkowej wiedzy. Istnieją jeszcze bardziej zaawansowane narzędzia synchronizacji niż muteksy, a problemy zakleszczeń są na tyle istotne, że powstały specjalne algorytmy je rozwiązujące.

8.1 Problem producent-konsument

Problem producent-konsument to podstawowy przykład utrudnienia na jakie napotykamy tworząc asynchroniczny program. Mamy tutaj ograniczony, współdzielony bufor o pojemności **n**, współdzieloną zmienną **counter** o wartości początkowej i 2 procesy, które próbują "dobrać" się do danych.

Dane współdzielone:

```
#define BUFFER_SIZE 4
typedef struct { . . . } item;
item buffer[BUFFER_SIZE];
int in = 0, out = 0, counter = 0;
```

Producent:

```
while (true) {
/* produce an item in next_produced */
while (counter == BUFFER_SIZE) ;/* buffer full? */
buffer [in] = next_produced;
in = (in + 1) % BUFFER_SIZE;
counter++;
}
```

Konsument:

```
while (true) {
while (counter == 0) ; /* buffer empty? */
next_consumed = buffer[out];
out = (out + 1) % BUFFER_SIZE;
counter--;
/* consume the item in next_consumed */
}
```

W skrócie chodzi o to, że producent zapełnia bufor zapętlając się od początku, a konsument odbiera to co wpisał producent. Procesy komunikują się za pomocą countera, który mówi ile jest aktualnie wyprodukowanych, nieodebranych zasobów.

Gdzie jest problem? **counter** jest inkrementowany i dekrementowany przez

dwa asynchroniczne procesy. Z poziomu asemblera, który operuje na rejestrach inkrementacja może wyglądać tak:

```
1 R1 = counter R2 = counter
2 R1 = R1 + 1
3 counter = R1
```

Producent po pobraniu countera do rejestru, ale przed zwiększeniem o 1, konsument może go pobrać w celu dekrementacji. Możliwy scenariusz

- counter = 4
- producent pobiera, R1 = 4
- konsument pobiera, R2 = 4
- producent inkrementuje, R1 = 5
- konsument dekrementuje, R2 = 3
- producent zapisuje, counter = 5
- producent zapisuje, counter = 3

A oczywiście poprawnie counter = 4

Taką sytuacje nazywamy **wyścigiem** (data race). W następnych punktach opisane są możliwości radzenia sobie z takimi problemami.

8.2 Problem sekcji krytycznej

Problem sekcji krytycznej pojawia się w przypadku gdy n procesów współzawodniczy w dostępie do współdzielonej danej, a fragment kodu w którym proces występuje dostęp do współdzielonych danych nazywamy **sekcją krytyczną**. Rozwiązaniem jest gwarancja, że tylko jeden proces znajduje się w swojej sekcji krytycznej. Jakie są zasady takich rozwiązań?

1. Wzajemne wykluczanie (mutual exclusion) – Tylko jeden proces znajduje się w swojej sekcji krytycznej.
2. Postęp (progress) – Jeśli żaden proces nie jest w sekcji krytycznej i istnieją takie, które chcą w nie wejść, to tylko te procesy, które nie mają aktualnie kodu poza sekcją krytyczną do wykonania mogą wejść. I trzeba w końcu jakiś wybrać.

3. Ograniczone czekanie (bounded waiting) – Musi istnieć ograniczenie na liczbę wejść INNYCH procesów do sekcji krytycznych po tym jak DANY proces zgłosił chęć wejścia i zanim dostał zgodę. W skrócie: proces nie może czekać na wejście w nieskończoność bo inne będą wchodzić przed kolejkę.

8.3 Algorytm Petersona

Podstawowa wersja algorytmu zakłada 2 procesy: P_0 i P_1. Zakładamy, że operacje maszynowe *load* i *store* są atomowe. Procesy współdzielą dane: **bool flag[2] = {false, false}** i **int turn**. Oba mają takie fragmenty kodu:

Kod przed sekcją krytyczną dla P_0:

```
flag[0] = true;
turn = 1;
while (flag[1] == true && turn == 1) ;
```

Kod po sekcji krytyczne dla P_0:

```
turn[0] = false;
```

Kod przed sekcją krytyczną dla P_1:

```
flag[1] = true;
turn = 0;
while (flag[0] == true && turn == 0) ;
```

Kod po sekcji krytyczne dla P_1:

```
turn[1] = false;
```

Jeśli działanie jest niezrozumiałe: w tablicy flag proces ustawia true na swojej wartości, gdy sygnalizuje, że chce wejść do sekcji krytycznej, a potem przez zmianę turn na wszelki wypadek "oddaje pierwszeństwo" drugiemu procesowi w razie gdyby tamten już był dalej w kodzie. Potem sprawdza czy rzeczywiście tak jest, czyli jeśli proces przeciwny ma ustawioną chęć wejścia do sekcji i jest jego kolej, wtedy poczeka w pętli aż tamten skończy i zmieni chęć po wyjściu z kodu.

8.4 Sprzętowe wspomaganie synchronizacji

Systemy zazwyczaj posiadają środki do sprzętowego wspomagania obsługi sekcji krytycznej. W systemach z jednym procesorem można wyłączyć obsługę przerwań – nieefektywne w systemach wieloprocesorowych. Aktualnie procesory są

wyposażone w instrukcje **atomowe**, czyli nieprzerywalne. Mogą być one wykorzystywane do synchronizowania procesów. Przykładowe instrukcje atomowe, które mogą być wspierane:

- **void swap(bool &a, bool &b)** – zamienia dwie zmienne miejscami
- **bool test_and_set(bool &cel)** – zwróci wartość zmiennej i ustawi na inną.

8.4.1 Wzajemne wykluczanie

Przykładowe użycie sprzętowego wspomagania do implementacji wzajemnego wykluczania Zmienna dzielona: **bool lock = false**

Kod przed sekcją krytyczną dla P_i:

```
while (test_and_set(lock));
```

Kod po sekcji krytyczne dla P_i:

```
lock = false;
```

8.4.2 Wzajemne wykluczanie z ograniczonym czekaniem

Przykładowe użycie sprzętowego wspomagania do implementacji wzajemnego wykluczania z ograniczonym czekaniem Zmienna dzielona: **bool lock = false, waiting[n] = {false,...,false}**

Kod przed sekcją krytyczną dla P_i:

```
waiting[i] = true;
key = true;
while (waiting[i] && key)
  key=test_and_check(lock);
waiting[i] = false;
```

Kod po sekcji krytyczne dla P_i:

```
j = (i+1) % n;
while ( j != i && !waiting[j] ) j= (j+1) % n;
if ( j == i ) lock = false;
else waiting[j] = false;
```

Kod powyżej warto przeanalizować samemu. Zasada działania polega na tym, że proces który wyszedł z sekcji krytycznej, daje pierwszeństwo wykonania

pierwszemu czekającemu procesowi po sobie – jeśli taki istnieje. Prowadzi to do sytuacji, w której żaden proces nie będzie czekał w nieskończoność, nawet jeśli inny proces dołączył do kolejki oczekujących razem z nim. Problem tego rozwiązania to **aktywne oczekiwanie** (busy waiting), bo proces w oczekiwaniu na dostęp będzie cały czas wykonywał pętle while.

8.5 Semafory

8.5.1 Co to jest semafor?

Semafor to mechanizm synchronizacji bardziej zaawansowany od **mutexów** – pozwala na kontrolę nad zasobem, który ma skończoną liczbę instancji. Jest to zmienna, do której możemy się dostać poprzez dwie operacje atomowe: *wait()* i *signal()*.

wait(S):

```
wait(S) {
while (S <= 0)
; // busy wait
S--;
}
```

signal(S):

```
signal(S) {
S++;
}
```

S to liczba dostępnych instancji zasobu. Gdy proces chce skorzystać z zasobu, używa *wait()*, gdy zwalnia używa *signal()*. Gdy liczba zasobów wynosi 1, mamy **semafor binarny** (wtedy działanie takie jak mutex), gdy więcej to **semafor zliczający**.

8.5.2 Problem busy waiting

Nasz podstawowy semafor ma problem z busy waiting, aby to wyeliminować można dodać do semafora oprócz liczby dostępnych instancji zasobu, listę oczekujących procesów:

Roszerzony semafor

```
typedef struct {
int value;
struct process *list;
} semaphore;
```

Wtedy zakładając, że nasz system implementuje operacje: *sleep()* i *wakeup()*, nasza implementacja wygląda tak:

wait(S):

```
wait(semaphore *S) {
S->value--;
if (S->value < 0) {
add this process to S->list;
sleep();
  }
}
```

signal(S):

```
signal(semaphore *S) {
S->value++;
if (S->value <= 0) {
remove a process P from S->list;
wakeup(P);
  }
}
```

Należy wspomnieć, że to dalej nie eliminuje busy waitingu, ponieważ samo wykonanie *wait()* i *signal()* jest sekcją krytyczną i należy o to zadbać, ale zdecydowanie eliminuje ilość zmarnowanych cykli procesora.

8.6 Blokada i głodzenie procesów

Blokada to zjawisko gdy dwa lub więcej procesów czekają bezterminowo na zdarzenie, które może być jedynie wytworzone przez jeden z oczekujących procesów. (To w sumie chyba to samo co deadlock, będzie potem).

Głodzenie procesu – gdy czas oczekiwania na semafor jest bardzo długi lub nieograniczony wskutek niewłaściwego szeregowania procesów oczekujących.

Inwersja priorytetów – niskopriorytetowy proces, który zajął semafor potrzebny wykonującemu się procesowi o wyższym priorytecie, powoduje wstrzymanie tego drugiego (jak gdyby zyskiwał na „ważności").

8.7 Klasyczne problemy synchronizacji

8.7.1 Problem ograniczonego buforowania

Problem ograniczonego buforowania (The Bounded-Buffer Problem), inaczej zwany i wcześniej wspomniany problem "producent - konsument". Rozwiązanie problemu przy użyciu semaforów:

Współdzielone struktury:

```
int n;
semaphore mutex = 1;
semaphore empty = n;
semaphore full = 0;
```

Producent:

```
while (true) {
...
/* produce an item in next produced */
...
wait(empty);
wait(mutex);
...
/* add next produced to the buffer */
...
signal(mutex);
signal(full);
}
```

Konsument:

```
while (true) {
wait(full);
wait(mutex);
...
/* remove an item from buffer to next consumed */
...
signal(mutex);
signal(empty);
...
/* consume the item in next consumed */
...
}
```

8.7.2 Problem czytelników i pisarzy

8.7.3 Problem obiadujących filozofów

9 Zakleszczenia

Zakleszczenie (deadlock) występuje gdy dwa lub więcej wątków, wpada w stan oczekiwania na zasoby, które należą do innego czekającego procesu, w skutek czego czekanie nigdy się nie zakończy.

Jakie są metody radzenia sobie z deadlockiem?

- Zapewnić że system nigdy nie będzie w stanie zakleszczenia np. stosując różne algorytmy znajdywania zakleszczeń
- Nie przeszkadzamy systemowi znaleźć się w stanie zakleszczenia, ale umiemy wydobywać system z tego stanu.
- Ignorujemy problem, udając że problem zakleszczenia nigdy nie ma miejsca w naszym systemie. Paradoksalnie najczęstsze rozwiązanie ze względu na wydajność.

9.1 Graf alokacji zasobów

TODO

10 Interfejs gniazd

Gniazda reprezentują punkt końcowy komunikacji. Każde gniazdo ma typ i określony protokół. Są one dostępne przez deskryptor przydzielany przez system przy jego tworzeniu. Gniazda w domenie lokalnej (UNIX) są widoczne w systemie plików jako pliki specjalne typu **socket** i wykorzystuje się je do komunikacji międzyprocesowej w obrębie tego systemu. Można do nich pisać i z nich czytać tak jak to wygląda w normalnych plikach lub łączach.

W przeciwieństwie do łączy, gniazda wspierają komunikacje pomiędzy niepowiązanymi procesami, a nawet pomiędzy procesami działającymi na różnych urządzeniach, komunikujących się poprzez sieć!

Tworząc łącze musimy określić sposób komunikacji: jaka będzie jednostka transmisji?, czy dane mogą zostać utracone w trakcie komunkacji?, jak wiele

socketów będzie brało udział w komunikacji?.

11 Zarządzanie pamięcią

11.1 Wprowadzenie

Podstawowym centrum operacyjnym w nowoczesnym komputerze jest pamięć składająca się z wielkich tablic bajtów posiadających adresy. Z perspektywy jednostki pamięci, widzi ona tylko strumień adresów bez wiedzy skąd pochodzą. CPU ma bezpośredni dostęp jedynie do pamięci głównej i rejestrów wbudowanych w rdzenie - nie ma bezpośredniego dostępu do pamięci dyskowej.

Dla prawidłowego działania systemu, należy chronić dostęp do pamięci przez różne procesy, tak aby było to bezpieczne dla innych procesów.

Zakładamy, że każdy proces ma swoją oddzielną przestrzeń adresów - zakres adresów (w liczbach) do których mogą się dostać. Ochrona ta jest zapewniana przez dwa specjalne rejestry: **base register** i **limit register**. Ten pierwszy określa od którego adresu zaczyna się przestrzeń procesu, ten drugi określa wielkość przestrzeni. Te rejestry są ładowane tylko przez system operacyjny przy użyciu specjalnych instrukcji uprzywilejowanych. Każda prośba CPU o dostęp do adresu wykraczającego poza ograniczenia wyznaczone przez rejestry skutkuje pułapką systemową **trap**.

11.2 Proces kompilacji

Zwykle program znajduje się na dysku w postaci pliku binarnego. Plik binarny jest efektem kompilacji kodu źródłowego, jednak następuję to w kilku krokach.

Najpierw kompilator produkuje z kodu źródłowego pliki obiektowe **object files**, które mogą być załadowane do pamięci fizycznej. **Pliki obiektowe** to pliki, które zawierają skompilowany kod w wersji relokowalnej. Zwykle jest to kod maszynowy lub język przejściowy (Intermediate Language). Ważną cechą jest to, że NIE jest to kod wykonywalny i służy do tego żeby ewentualnie połączyć go z innymi plikami obiektowymi i dopiero wyprodukować potem plik binarny. Zawiera on również różne metadane, które służą za wskazówki dla dalszej pracy kompilatora odnośnie adresów.

Następnie skompilowane pliki obiektowe trafiają do konsolidatora (**linkera**). Który dokonuje powiązania pomiędzy różnymi plikami obiektowymi. W trakcie tej fazy mogą być dołączane np. różne biblioteki standardowe. Efektem tych połączeń jest pojedynczy plik wykonywalny **executable**. W rzeczywistości jed-

nak systemy operacyjne wspierają dynamiczne podłączanych bibliotek **DLL - dynamically linked library**. Bez tego mogło by dojść do zbędnego kopiowania bibliotek do pliku wykonywalnego, przez co miałby on ogromne rozmiary. Drugą zaletą jest również możliwość tworzenia współdzielonych bibliotek

Ostatnia faza to ładowanie, w której **loader** ładuje plik wykonywalny do pamięci operacyjnej i przygotowuje go do wykonania. Dochodzi w tych etapach do aktywności zwanej relokacją (**relocation**), która przypisuje ostateczne adresy programowi. Po dokonanym ładowaniu, jądro oddaje kontrolę w ręce załadowanego programu. Można również ładować dynamicznie w trakcie wykonywania (jeśli hardware wspiera takie operacje).

11.3 Powiązanie adresów

Początkowo proces odwołuje się w pamięci do adresów, które finalnie nie są rzeczywistymi adresami w pamięci fizycznej. Np, odwołanie się do adresu 0, wcale nie musi być 0 w pamięci RAM, dlatego że początkowo proces nie wie w jakim miejscu się znajdzie i do jakiej pamięci rzeczywistej powinien się odnieść.

Dlatego adresy są reprezentowane w trakcie kompilacji w różny - czasem symboliczny sposób, a powiązanie między adresami symbolicznymi, a rzeczywistymi może nastąpić w różnych momentach:

- **Compile time** – Adres bezwzględny jest znany od początku - wiemy w jakim miejscu będzie znajdywał się proces użytkownika. Jeżeli lokacja później się zmieni, trzeba będzie rekompilować kod.
- **Load time** – Jeśli nie znamy miesjca kodu w trakcie compile time to kod musi być wygenerowany w postaci relokowalnej **relocatable code**. Teraz powiązanie jest dokonywane już po załadowaniu programu do pamięci. Jeśli adresy się zmienią, trzeba będzie jedynie ponownie załadować program do pamięci.
- **Execution time** – Jeśli proces może zmienić swoje położenie w trakcie wykonywania, wtedy powiązanie również musi być wtedy dokonane - musi istnieć wsparcie sprzętowe.

11.4 Logiczna i fizyczna przestrzeń adresowa

Adresy logiczne to te, które generuje i do których odnosi się CPU.

Adresy fizyczne to te, które widzi jednostka pamięci (memory unit), biorąc ją z rejestru pamięci adresowej **memory-addres register**(MAR) - to rejestr CPU, który służy do komunikacji z jednostką pamięci.

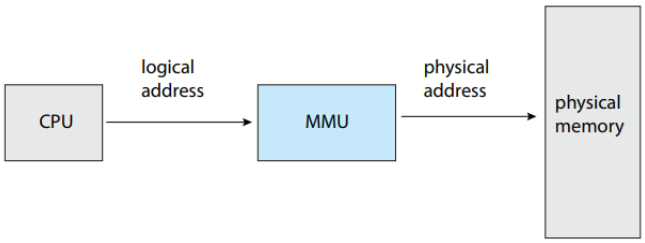

Rysunek 8: Schemat odwołania się do pamięci

Mapowania pomiędzy wirtualnymi, a fizycznymi adresami dokonuje urządzenie hardware'owe - **memory-management unit** (MMU). W uproszczonym modelu używamy rejestru relokacji **relocation register**, który jest nową nazwą na opisany wcześniej base register. Jego wartość jest dodawana do każdego odwołania się do pamięci systemowej przez proces.

11.5 Ciągły i dynamiczny przydział pamięci

Pamięć główna dzieli się na dwie części: część procesów użytkownika i część systemu operacyjnego. Gdy proces się tworzy, dostaje przydział pamięci dla siebie w ciągłym bloku pamięci operacyjnej. Potem gdy proces ginie lub się kończy, jego pamięć zostaje zwolniona. W trakcie trwania systemu wiele procesów kończy się i zaczyna w różnym czasie tworząc dziury. Generalnie jest przez to spory bałagan i powstaje dużo problemów odnośnie tego w jaki sposób przydzielać miejsce na nowe procesy. Istnieją 3 algorytmy z czego jedynie pierwsze 2 mają jakikolwiek sens:

- **First fit** – Przydzielamy adresowi pierwszą dziurę, która jest na niego wystarczająco duża.
- **Best fit** – Znajdujemy i przydzielamy najmniejszą dziurę spośród wystarczająco dużych dla danego procesu. (Trzeba szukać!)
- **Worst fit** – Przydzielamy największą możliwą dziurę. (Bez sensu)

Nie ważne jaki algorytm wybierzemy, około połowa pamięci i tak zginie zostanie zmarnowana przez fragmentacje. Zasada ta nazywa się Zasadą 50 procent (**50-percent rule**).

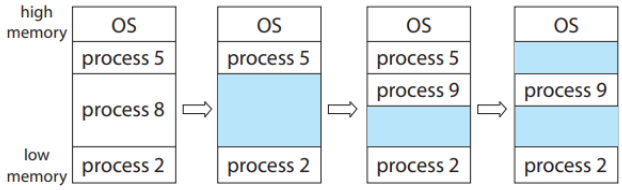

Rysunek 9: Powstawanie dziur w pamięci

11.6 Fragmentacja

Fragmentacja zewnętrzna (external fragmentation) - to sytuacja, która następuje gdy mamy wystarczająco dużo miejsca w pamięci na proces, ale pamięć ta nie jest ciągła (składa się z dziur po powstawaniu i znikaniu procesów).

Fragmentacja wewnętrzna (internal fragmentation) - następuję gdy marnowane jest miejsce przydzielane dla procesu w postaci bloków, które są większe niż proces potrzebuje. Po co przydzielać pamięć w blokach? Hipotetycznie proces mógłby zarządać 999 z 1000 dostępnych bajtów. Nakład pamięci by pilnować ten ostatni bajt byłby większy niż on sam.

Aby zapobiec marnowaniu miejsca można zastosować jedną z dwóch opcji:

- **Scalanie (compaction)** – W przypadku braku miejsca przesuwamy wszystkie procesy w pamięci tak żeby były koło siebie. Drogie, niepraktyczne i możliwe tylko gdy ustalanie adresów jest dynamiczne i dzieje się w trakcie wykonania (execution time).
- **Stronicowanie (paging)** – Pozwolenie logicznej przestrzeni adresowej na bycie nieciągłą i w ten sposób pozwalając procesowi być rozbitym w fizycznej pamięci w różnych miejscach. Ten sposób jest bardziej powszechny.

11.7 Stronicowanie

11.7.1 Opis

Podstawowe założenie to dzielenie pamięci fizycznej na bloki stałej wielkości - **ramki (frames)** i dzielenie pamięci logicznej na odpowiadające ramkom bloki - **strony (pages)**.

Każdy adres generowany przez CPU dzieli się na dwie części - **numer stro-**

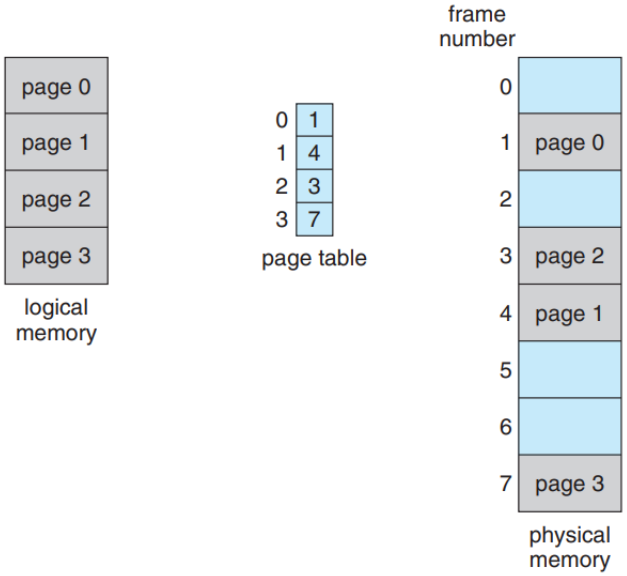

Rysunek 10: Stronicowanie

ny i **offset**. Istnieje specjalna tablica stron dla procesu w przestrzeni jądra - **page table**, do której MMU odwołuje się by przetłumaczyć numer strony na odpowiedni numer ramki w pamięci fizycznej. Dzieje się to przy każdym odwołaniu do pamięci przez CPU. Istnieje również globalna tablica ramek **frame table**, śledząca to czy dana ramka jest wolna czy zajęta.

Stronicowanie eleminuje external fragmention, ale internal fragmentation dalej istnieje.

11.7.2 Wsparcie sprzętowe

Tablice stron są strukturą per-proces i wskaźnik na nią jest trzymany w rejestrach jako struktura PCB (Process Control Block). Implementacja może być zrealizowana przez trzymanie całej tablicy stron w rejestrach procesora (efektywne dla małych tablic), jednak większość CPU wspiera dużo większe tablice stron. Wtedy tablica jest trzymana w pamięci głównej i istnieje jedynie specjalny rejestr z adresem na nią - **page-table base register** (PTBR).

W przypadku context-switchingu zmieniamy tylko wartość rejestru PTBR.

Jednak trzymanie tablicy stron w pamięci ma wadę - memory access kosz-

tuje więcej niż dostęp do rejestru. Rozwiązaniem jest specjalny, mały i szybki cache nazwany buforem translacji adresów stron (**translation look-aside buffer (TLB)**).

Każdy wpis w TLB składa się z dwóch wartości: numeru strony i numery ramki. Przy odwołaniu się do strony MMU najpierw przeszukuje TLB i jeśli nie znajdzie wpisu dodaje go z pamięci. W ten sposób często odwiedzane strony ładują się szybciej.

Niektóre TLB przechowują identyfikar przestrzeni adresowej **address-space identifier (ASID)** w każdym wpisie. W ten sposób nie trzeba czyścić TLB po każdym przełączaniu kontekstu (czyści się żeby przypadkiem nie odwołać się do ramek innego procesu).

Obecnie procesory posiadają wielopoziomowe, skomplikowane TLB i opis wyżej jest jedynie uproszczeniem.

11.7.3 Ochrona pamięci

Do opisanej wyżej tablicy stron (page table) może zostać dodany bit poprawności **valid-invalid**. Stan poprawny oznacza że strona znajduje się w logicznej przestrzeni adresowej procesu. Stan niepoprawny oznacza że proces wykracza poza swój limit i zostanie wywołana pułapka (trap) w przypadku odwołania się do tej strony. (Bit ten będzie mógł być wykorzystany do implementacji pamięci wirtualnej)

Może zostać również dodany bit ochrony w celu zaznaczenia, że jakaś ramka jest przeznaczona tylko do odczytu.

W niektórych systemach jest również hardware'owy rejestr **page-table length register (PTLR)**, w którym trzyma się rozmiar aktualnej tablicy stron. W tym rozwiązaniu przy każdym odwołaniu się do pamięci wirtualnej nastepuje sprawdzenie czy dany adres jest w prawidłowym zakresie.

11.7.4 Współdzielenie stron

Niektóre strony używane przez wiele procesów mogą być współdzielone (np. biblioteka libc w Linuxie) po to żeby zaoszczędzić miejsce. Strony te muszą być dostępne tylko do odczytu, dlatego zwykle na współdzielonych stronach znajdują się biblioteki systemowe lub często używane programy: kompilatory, systemy bazodanowe itp.

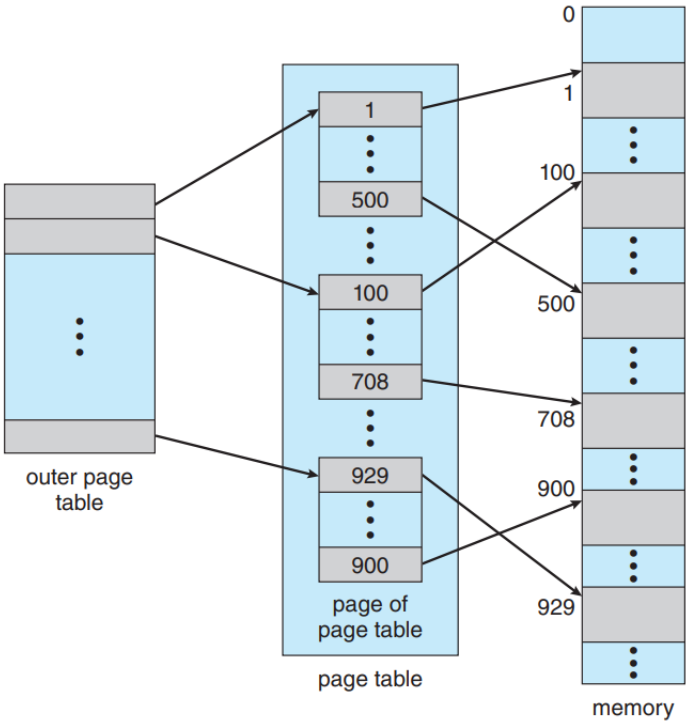

Rysunek 11: Dwupoziomowe stronicowanie

11.8 Struktura tablicy stron

W typowym systemie operacyjnym stron może być bardzo wiele, dlatego tworzenie tablicy stron jako zaalokowanej sztywnej struktury może być zbyt kosztowne. Istnieją inne lepsze rozwiązania.

11.8.1 Stronicowanie hierarchiczne

Stosujemy 2 lub 3 poziomowe stronicowanie. Jako adres podajemy zewnętrzny numer tablicy, wewnętrzny numer tablicy oraz offset.

11.8.2 Hashowane tablice stron

Możemy używać funkcji haszujących konwertujących numer wirtualnej strony w tablicę stron. Elementy tablicy stron wskazują na listy par strona-ramka. Przy

podaniu adresu funkcja haszująca przekształca podany numer strony w adres do listy i przeszukuje listę w poszukiwaniu odpowiedniego odwołania do ramki.

11.8.3 Odwrócona tablica stron

Normalna tablica stron ma następujący problem: każda strona ma odpowiadający wpis w tablicy stron, przez co może ona zajmować miliony wpisów. Z tego powodu sama tablica zajmuje dużo pamięci fizycznej tylko po to, żeby wiedzieć jak używana jest pamięć fizyczna przez proces.

Problem ten jest rozwiązany przez odwróconą tablicę stron. W tym rozwiązaniu istnieje tylko jedna tablica dla całego systemu, a wpisy składają się z numeru strony, numeru ramki i **numeru procesu** posiadającego ramkę.

Zaletą tego rozwiązania jest to, że nie ma potrzeby tworzenia oddzielnej tablicy stron dla każdego procesu. Wadą jest potrzeba przeszukiwania ogromnej tablicy wspólnej dla wszystkich procesów w celu odnalezienia dopasowania oraz brak możliwości współdzielenia stron (bo każdej fizycznej ramce odpowiada jedna strona wirtualna posiadana przez konkretny proces).

11.9 Swapping

Swapping to przenoszenie danych związanych z procesem do pamięci twardej systemu wtedy gdy brakuje miejsca w pamięci operacyjnej. Jest to zachowanie kosztowne w czasie ze względu na wolny czas operacji dyskowych. W obecnych czasach częściej używa się swappingu z wymianą stron - zamiast całego procesu swappujemy tylko niektóre strony co oszczędza czas bo nie musimy zapisywać całego procesu. Obecnie na swapping ze stronami używa się określenia **paging**.

11.10 Intel 32, Intel-64, ARMv8

Opcjonalnie.

12 Pamięć wirtualna

12.1 Podstawy

Pamięć wirtualna to technika, która umożliwia procesowi na wykonywanie się nie będąc całkowicie w pamięci fizycznej. Główną zaletą jest posiadanie przez

program większych rozmiarów niż rzeczywista pamięć fizyczna. Umożliwia ona uruchomianie programów, które nie są w całości załadowane do pamięci. Po co?

- Niektóre programy posiadają kod do obsługi bardzo nietypowych błędów przez co nie jest on prawie nigdy wykonywany.
- Niektóre struktury danych: listy, tablice posiadają zaalokowane dużo więcej pamięci niż rzeczywiście potrzebują.

12.2 Stronicowanie na żądanie

Rozwiązaniem na konieczność ładowania całego programu do pamięci zanim go uruchomimy jest stronicowanie na żądanie **demand paging**. W tym rozwiązaniu, strony są ładowane tylko jeśli są potrzebne w pewnym momencie w trakcie wykonywania programu. Potrzebujemy jedynie pakietu stron na start programu. Jest to system podobny do swappingu.

Do implementacji może być wykorzystany bit poprawności w tablicy stron. Gdy strona jest załadowana do pamięci ustawiamy bit na "valid", gdy nie jest - na "invalid". Odwołanie się do strony oznaczonej jako invalid oznacza, że nie jest ona załadowana do pamięci lub nie jest poprawna. Takie odwołanie nazywamy **page fault**. Page fault wywołuje pułapkę systemową, która jest obsługiwana w następujący sposób:

1. Sprawdzamy wewnętrzną tabelę (zwykle trzymaną razem z PCB) w celu sprawdzenia czy odwołanie było prawidłowe.
2. Jeśli było prawidłowe, rozpoczynamy procedurę ładowania strony do pamięci
3. Najpierw znajdujemy wolną ramkę
4. Planujemy ładowanie strony do nowo zaalokowanej ramki
5. Po załadowaniu, modyfikujemy wewnętrzną tabelę zaznaczając, że dana strona jest obecna w pamięci
6. Restartujemy instrukcję przerwaną przez pułapkę

Jedną z taktyk jest **lazy swapping** – ładowanie strony do pamięci tylko i wyłącznie gdy jest ona potrzebna .

Uruchomianie procesu do pamięci bez żadnej strony nazywamy czystym stronicowaniem na żądania (**pure demand paging**).

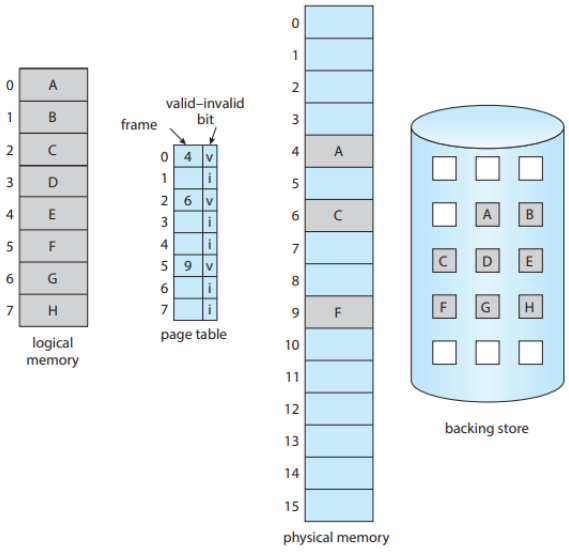

Rysunek 12: Pamięć wirtualna z wykorzystaniem bitu poprawności

Aby zagwarantować minimalizacje page fault'ów należy używać lokalnych odniesień do pamięci, ponieważ systemy zwykle układają sekwencyjnie. To znaczy, że zmienne zaalokowane względnie blisko siebie w kodzie, z większym prawdopodobieństwem znajdą się na tej samej stronie.

Wymagania sprzętowe stronicowania na żądanie:

- Tablica stron z bitem poprawności dla każdej strony
- Obecna pamięć stronicowania (swap device)
- Możliwość wznawianie rozkazu, który wywołał błąd braku strony

Page fault jest największym obciążeniem czasowym dla taktyki stronicowania na żądanie. Każde odwołanie się do strony, która nie znajduje się obecnie w pamięci prowadzi w najgorszym wypadku do następujących kroków:

1. Pułapka uruchamia tryb uprzywilejowany jądra
2. Zapisujemy rejestry i stan procesu
3. Sprawdzamy czy odwołanie do strony było legalne i określa jej lokalizacje na dysku

4. Zamawiany jest odczyt strony z dysku do wolnej pamięci RAM (przyjęcie zlecenia przez sterownik dysku, znalezienie bloku na dysku, przesłanie strony)
5. W czasie oczekiwania procesor może robić co innego
6. Otrzymano przerwanie I/O dysku po zakończeniu przesłania strony
7. Context switching - bo przecież procesor robił co innego
8. Obsługa I/O dyskowego
9. Modyfikacja tablicy stron
10. Odtworzenie stanu procesu, który wywołał page fault i wznowienie go

12.3 Zastępowanie stron

W momencie gdy używamy stronicowania na żądanie, może wyniknąć następująca sytuacja: istnieje 10 procesów 10 stronowych i każdy z nich ma obecnie załadowane do pamięci po 5 stron. Gdy całkowita pamięć jest w stanie pomieścić 50 ramek, może nastąpić sytuacja, że któryś z procesów zażąda kolejnej strony, na którą nie mamy już miejsca. Aby to rozwiązać stosuje się zastępowanie stron **page swapping**.

Gdy nie ma wolnych ramek, szukamy ofiary **victim frame** do zastąpienia. Zastępujemy znalezioną ramkę, nową ramką i modyfikujemy tablicę stron/ramek. To rozwiązanie zwiększa liczbę page fault'ów, bo ta sama ramka może wywołać page fault kilkukrotnie.

Każda zamiana teorytycznie powinna wywołać dwa transfery: jeden na załadowanie nowej ramki, drugi na zapisanie starej z powrotem do pamięci trwałej. Żeby to zminimalizować stosuje się **dirty bit**, który jest ustawiony jeśli ramka była modyfikowana. Jeśli nie jest on ustawiony, nie trzeba zapisywać starej ramki ponieważ taka sama kopia znajduje się już w pamięci.

Przy implementacji stronicowania na żądanie należy wymyślić dwa algorytmy: przydziału ramek **frame-allocation algorithm** i zastępowania stron **page-replacement algorithm**.

12.4 Algorytmy zastępowania stron

W przykładach będziemy zakładać, że możemy mieć maksymalnie 3 przydzielone ramki. Efektywność algorytmu liczy się poprzez liczbę wygenerowanych page fault'ów

12.4.1 Algorytm FIFO

Algorytm ten zastępuje najdawniej załadowaną stronę w pamięci. Dla niektó-

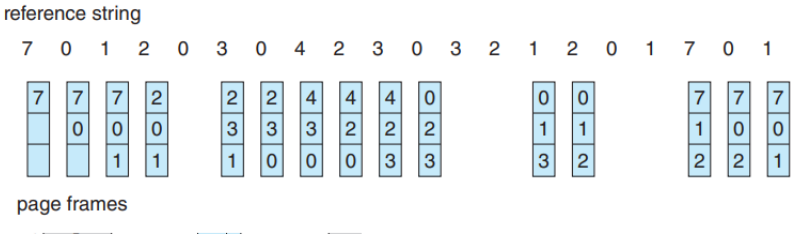

Rysunek 13: Symulacja algorytmu FIFO

rych algorytmów zwiększenie ilości dostępnych ramek zwiększa ilość page fault'ów. Zjawisko to jest nazywane anomalią Belady'ego **Belady's anomaly**.

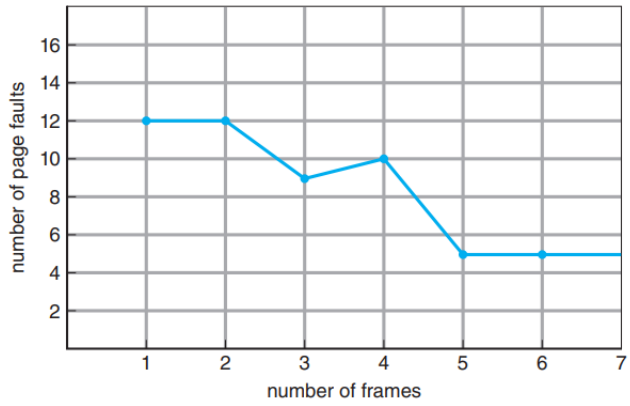

Rysunek 14: Anomalia Beladyego

12.4.2 Algorytm Optymalny (OPT)

Algorytm, który zastępuje stronę, które najdłużej nie będzie używana. W teorii najlepszy algorytm, który jest kompletnie niepraktyczny, ponieważ nie jesteśmy w stanie przewidzieć przyszłości i tego jakie ramki będą użyte.

12.4.3 Algorytm Least-Recently Used (LRU)

Wymienia stronę, która najdłużej nie była używana. Ogólnie dobry, często stosowany algorytm. Problemem jest jedynie jak zaimplementować LRU. Występują

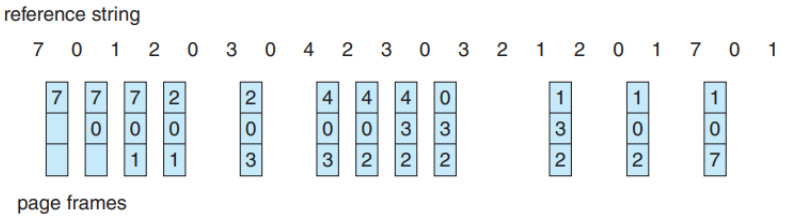

Rysunek 15: Algorytm LRU

dwie wersje: stosowa i z licznikiem.

- Stosowa - przechowuje stos numerów stron w liście dwukierunkowej. Odnoszenie się do stron zmienia jej pozycje na liście. Ofiara jest zawsze na dole stosu.
- Z licznikiem - Przy każdej operacji odwołania się do strony zwiększamy licznik i przypisujemy do użytej strony. Strona z najmniejszym licznikiem staje się ofarią.

Istnieją również algorytmy przybliżające LRU:

- Bit odniesienia - dla każdej strony domyślnie ustawiony na 0, przy odniesieniu zmieniany na 1. Można zastąpić strony z bitem 0.
- Algorytm drugiej szansy - Obecny bit odniesienia oraz jeśli przy zastępowaniu bit odniesienia równy 1 to zamieniamy na 0 (Stopniowa degradacja stron). Ulepszona wersja dodaje jeszcze bit modyfikacji ustawiany gdy modyfikujemy stronę.

12.4.4 Buforowanie stron

Oprócz wyżej wymienionych algorytmów system zwykle dba o to, aby trzymać pulę wolnych ramek. Ramka jest dostępna natychmiast gdy będzie potrzebna do obsługi błędu braku strony. Ofiara jest wybierana i może być używana zanim będzie usunięta z puli ramek załadowanych (choć być może użycie jej zabierze ją z puli wybranych do unicestwienia).

12.5 Przydział ramek

Każdy proces potrzebuje minimalnej liczby stron do działania. Potem istnieją różne sposoby na przydział liczby dostępnych ramek dla każdego procesu. Podział algorytmów ze względu na przydział ilości ramek:

- **Przydział równy** – Każdy proces ma taką samą liczbę ramek do dyspozycji
- **Przydział priorytetowy** – Każdy proces ma priorytet i procesy o wyższym priorytecie mogą odbierać ramki procesów z niższym priorytetem

Ze względu na to, w jaki sposób ramki są alokowane zaalokować mamy podziały:

- **Globalna zamiana** – Proces o wyższym priorytecie może odebrać ramki innemu procesowi o niższym priorytecie
- **Lokalna zamiana** – Procesy mogą korzystać tylko z ramek przydzielonych do ich własnej puli

12.6 NUMA

Jak dotąd opisywane przyłady zakładały równy dostęp do pamięci głównej. W praktyce tak się nie dzieje i pamięć operacyjna jest podzielona na obszary i do każdego z nich istnieje inny czas dostępu.

W systemach z większą ilością CPU występuje niejednolity dostęp pamięci **non-uniform memory access (NUMA)**. W tym rozwiązaniu każde CPU ma swoją lokalną pamięć, do której dostęp dla nich jest szybszy niż do pamięci lokalnej innych CPU. Ten układ jest zdecydowanie wolniejszy niż dostęp jednolity, jednak umożliwia on wielowątkowość i jest stosowany w każdej współczesnej architekturze.

NUMA komplikuje sposób w jaki należy przydzielać ramki procesom. Ogólne optymalne rozwiązanie jest takie, żeby przydzielać zasoby jak najbliżej rdzenia, który z nich korzysta (fizycznie znajdą się ona bliżej siebie na płytkach).

12.7 Szamotanie

Szamotanie **thrashing** występuje gdy proces aktywnie używa wiele ramek na raz i brakuje mu kolejnych. W takiej sytuacji następuję wielokrotny page fault, ponieważ proces cały czas zmienia ramki - wyrzuca je i zaraz są one potrzebne

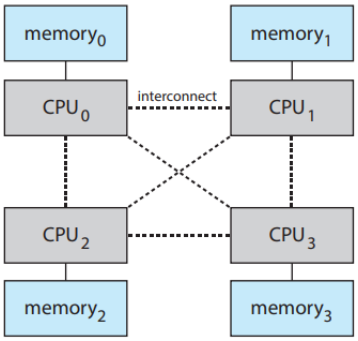

Rysunek 16: Architektura NUMA

znowu. Na skutek takiej operacji proces spędza więcej czasu na stronicowanie niż wykonywanie.

Powodem thrashingu może być system operacyjny, który widząc niskie wykorzystanie procesora próbuje zwiększyć poziom wieloprogramowości dodając nowe procesy. Nowe procesy wymagają wolnej pamięci odbierając ramki już istniejącym procesom. Procesy, którym odebrano ramki page faultują przez co dokonują swappingu i oczekując w kolejce na urządzenie stronicujące znowu zmniejszają zużycie procesora. Wtedy system operacyjny znowu tworzy procesy i cykl się powtarza dopóki system się nie zapcha i większość procesów będzie stale page faultować.

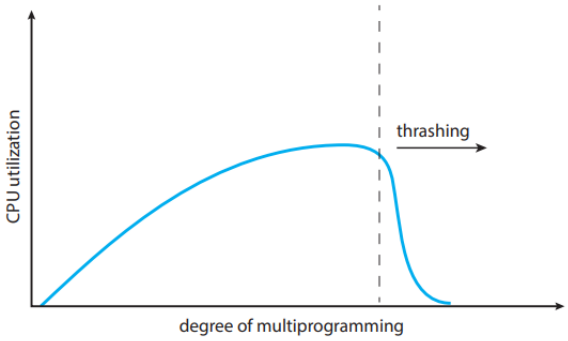

Rysunek 17: Stopień wieloprogramowości, a liczba page faultów

Generalnie żeby zapobiec thrashingowi należy znaleźć proces, który będzie miał tyle ramek ile potrzebuje do wykonania. W celu przybliżenia, który to jest stosuje się model strefowy **locality model**. Jest to założenie, że proces w trakcie

wykonywania przechodzi ze strefy do strefy. Strefa to zbiór wykorzystywanych przez proces ramek położonych blisko siebie. Heurystyka jest taka, że zakładamy lokalność danych - w ogólności proces ma tendencje do korzystania z danych położonych blisko siebie.

Standardowym podejściem na uspokojenie thrashingu jest wyznaczenie procesu i uśpienie go. Poziom thrashingu wyznaczamy przez liczbę elementów w zbiorze roboczym. Bierzemy liczbę Δ i liczymy ile różnych stron zostało wywołanych w ostatnich Δ odwołaniach. Tym większa ta liczba jest, tym większy poziom szamotania.

W praktyce liczbę przydzielanych ramek kontroluje się przez wskaźnik częstości page faultów (**page-fault frequency (PPF)**). Jeśli proces generuje zbyt dużo page-faultów to potrzebuje więcej ramek. Jeśli generuje za mało, to znaczy że ma za dużo ramek i trzeba mu je odebrać bo marnuje zasoby.

12.8 Odwzorowanie plików w pamięci

Memory-mapped file I/O to logiczne skojarzenie wirtualnej przestrzeni adresowej z plikiem. Po takiej operacji jesteśmy w stanie operować na pamięci operacyjnej modyfikując plik bez potrzeby używania funkcji systemowych I/O. Zmiana zmapowanej pamięci niekoniecznie skutkuje natychmiastowym wykonaniem odpowiadającej operacji dyskowej. Byłoby to bardzo czasochłonne i niepraktyczne, ale w niektórych systemach możliwe do wykonania.

13 Systemy plików

13.1 Wstęp

Plik to nazwana logicznie jednostka magazynowania informacji. Pliki są zorganizowae w systemie plików, który pozwala na zarządzenie przechowywaniem informacji i wykonywanie operacji plikowych. Logiczne relacje plików są najczęściej przedstawione w formie grafu skierowanego acyklicznego.

Dysk jest głównym narzędziem służącym za pamięć drugorzędną (**secondary**). Dwie cechy, które sprawiają, że nadaje się do tego najlepiej to: możliwość wielokrotnego nadpisywania miejsca oraz bezpośredniego dostępu do każdego bloku informacji jaki zawiera - sekwencyjnie lub losowo. Dysk jest urządzeniem typu pamięci nieulotnej - **nonvolatile memory (NVM)**.

Podstawową jednostką na dysku jest **sektor** (512B - 4kB). W celu poprawy efektywności operacji I/O transfery są wykonywane w blokach (**blocks**). Każdy

blok składa się z jednego lub więcej sektorów.

System plików (**file system**) zapewnia efektywny i przystępny dostęp do urządzeń magazynujących (głównie dysków). Definiuje to w jaki sposób system powinien być widoczny z perspektywy użytkownika, w jaki sposób logicznie mają być przechowywane pliki oraz jakie algorytmy będą na nich używane.

System plików ma strukturę warstwową i składa się z modułów:

1. Aplikacje - komunikują się w sposób wysokopoziomowy
2. Logiczny system plików - zarządza metadanymi, kontekstem pliku, katalogiem do jakiego należy, zapewnia nazwę symboliczną itp. Utrzymuje struktury **file control block (FCB)** (implementowana jako **inode** w systemach UNIX).
3. Moduł organizacji plików - rozumie pliki i zna ich logiczne numery bloków. Zarządza organizacją i alokacją wolnych bloków dyskowych.
4. Podstawowy system plików - przekazuje wywołania dyskowe do odpowiednich sterowników. Zapewnia kontrole nad planowaniem operacji wejścia-wyjścia. Zarządza buforami pamięci i cache'ami, które są alokowane przed masowym transferem bloków.
5. Driver - Steruje operacjami wejścia/wyjścia na dysku na najniższym poziomie. Tłumaczy komendy w postaci "retrieve block 123" na niskopoziomowe hardware'owe instrukcje rozumiane przez kontroler dysku.

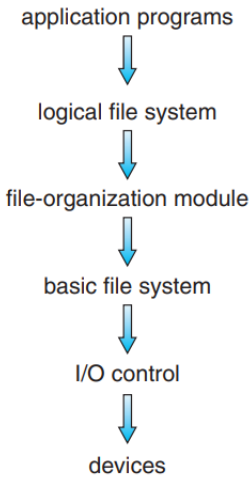

Rysunek 18: Warstwowa budowa dyskowego systemu plików

13.2 Wirtualne systemu plików

W systemach Linux może równolegle istnieć wiele różnych systemów plików, a mimo to w każdym miejscu możemy w ten sam sposób operować na plikach operacjami open/read/write... Ten wspólny interfejs jest nazwany wirtualnym systemem plików. Każdy FS (file system) musi implementować ogólnie określone API zapewnione przez programistę. Oddziela to operacje typowe dla systemów plików od ich implementacji.

Wirtualny system plików zapewnia jednolitą reprezentację pliku w pamięci operacyjnej w postaci struktury nazwanej **vnode** reprezentujący plik w pamięci jądra.

W Linuxowym VFW Zdefiniowane są 4 główne obiekty:

- **inode** – plik
- **file** – otwarty plik
- **superblock** – reprezentuje cały system plików
- **dentry object** – reprezentuje konkretny katalog

Standardowo tworzenie własnego systemu plików wymagałoby modyfikacji jądra systemu. Z tego powodu Linux udostępnia interfejs programistyczny **FUSE**, który umożliwia pisanie kodu obsługującego system plików w trybie użytkownika (nieuprzywilejowanym).

13.3 Operacje na systemie plików

Implementacja systemu plików wymaga szeregu struktur zarówna w pamięci operacyjnej jak i pamięci trwałej. W pamięci operacyjnej mogą znajdować się struktury takie jak:

- **Mount table** – tablica zawierająca informację o każdym zamontowanym woluminie (volume). Wolumin to wydzielony obszar pamięci masowej np. partycja na dysku, dyski CD/DVD.
- Struktura w cache'u zawierająca informacje o ostatnio używanych katalogach.
- **System-wide open file table** – zawiera kopie FCB każdego otwartego pliku.

- **Per-process open file table** – zawiera wskaźnik na wpis w system-wide open file table dla każdego otwartego pliku w procesie.

Odwołanie się do pliku w postaci otwarcia lub zapisu/odczytu modyfikuje te oraz zawarte na dysku struktury organizujące pliki i katalogi. Początkowo przeszukiwana jest tablica otwartych plików w celu upewnienia się czy plik nie jest już otwarty. Wpisy w strukturach odwołują się już do konkretnych bloków w pamięci masowej.

13.4 Implementacja katalogów

Katalogi mogą być zaimplementowane jako:

- Lista – liniowa lista nazw plików ze wskaźnikami do bloków danych. Prosta do implementacji i czasochłonna w przeszukiwaniu.
- Tablica haszująca – funkcja haszująca bierze nazwę pliku i zwraca wskaźnik do wpisu w liście. Szybkie szukanie, ale obecność kolizji i stały rozmiar tablicy.
- Drzewo – zmniejsza czas przeszukiwania, wydłuża operacje dodawania/usuwania pozycji.

13.5 Metody alokacji pamięci dla plików

Metoda alokacji określa w jaki sposób będą przydzielane bloki dyskowe do zapisu danych dla pliku. Obecnie stosowane są mieszanki wymienionych algorytmów w celu osiągnięcia najlepszej efektywności.

13.5.1 Przydział ciągły

Contiguous allocation – przydział ciągły wymaga aby plik zajmował zbiór ciągłych bloków w pamięci masowej. W ten sposób głowica dysku nie musi zmieniać drastycznie pozycji w przypadku sekwencyjnego dostępu do jednego pliku. Dodatkową zaletą jest mała ilość informacji określających położenie pliku - wystarczy numer bloku początkowego i długość określona w liczbie bloków.

Wady tego rozwiązania są bardzo podobne do ciągłej alokacji pamięci operacyjnej. Nie wiemy jak duży będzie plik, więc nie jesteśmy w stanie określić jego miejsca z góry, a z powodu konieczności sekwencyjnego ułożenia bloków nie jesteśmy w stanie dynamicznie przydzielać nowej pamięci. Występuje też

fragmentacja zewnętrzna. Możemy próbować scalać porozrzucane bloki, ale w przypadku dysków jest to bardzo niepraktyczne i może zająć wiele czasu.

Zmodyfikowana wersja alokacji ciągłej przydziela plikowi zbiór przylegających bloków nazywanych obszarami **extents**. Wtedy położenie pliku jest opisywane przez początek pierwszego obszaru, jego długość i połączenie do następnego obszaru. Obszary nie muszą już przylegać do siebie, więc to rozwiązanie to taka hybryda ciągłej i nieciągłej pamięci.

13.5.2 Przydział listowy

Linked allocation – plik jest reprezentowany przez listę nieciągle połączonych bloków. Rozwiązuje to problemy ciągłej alokacji, ale tworzy nowe. Dostęp musi być sekwencyjny, więc musimy przejść przez wszystkie bloki po kolei aby dostać się do ostatniego. Dla każdego bloku potrzebny jest też wskaźnik, który marnuje miejsce na dysku. Aby to zminimalizować łączy się bloki w klastry **clusters**.

Praktyczną modyfikacją przydziału listowego jest **FAT – file-allocation table**. Implementuje on na początku każdego woluminu tablicę, która posiada wpis dla każdego bloku indeksowany jego numerem i zawierający numer następnego bloku w pliku. Wartości w tablicy dla wolnych bloków są ustawiane na 0, a na ostatnie bloki w pliku na np. -1. Plik jest reprezentowany jako wpis strukturze katalogu zawierający nazwę pliku i blok początkowy. Schemat FAT może skutkować częstymi ruchami głowicy dysku, ale zwykle tablica FAT jest cache'owana co czyni to rozwiązanie względnie skutecznym.

13.5.3 Przydział indeksowy

Bez tablicy FAT, przydział listowy nie posiada dostępu bezpośredniego (random access) do bloków w pliku. Problem ten jest rozwiązany przez **indexed allocation**, która implementuje blok indeksowy **index block** zbierający wszystkie wskaźniki w jedno miejsce.

Każdy plik ma swój własny blok indeksowy w postaci tablicy adresów bloków. Problemem jest pytanie jak duży powinien być blok, ponieważ każdy plik ma swój własny i chcemy, żeby był jak najmniejszy. Rozwiązaniem może być wielopoziomowe indeksowanie, czyli zewnętrzny wpis w bloku indeksowym wskazuje na kolejny blok indeksowy z faktycznymi numerami bloków pliku. Innym rozwiązaniem jest użycie listy bloków indeksowanych przez co zawsze możemy dodać nowe bloki.

W praktyce, UNIXowy inode jest reprezentowany jako zmodyfikowany blok indeksowy z wielopoziomowymi tablicami używanymi w zależności od wielkości pliku.

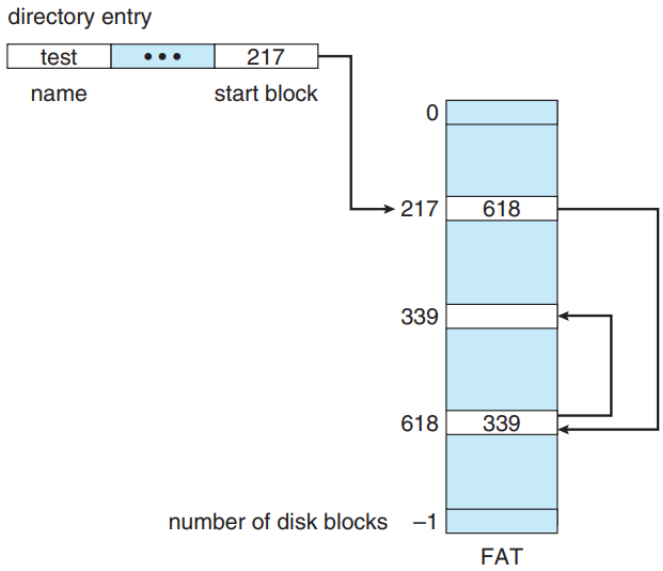

Rysunek 19: Schemat FAT

13.6 Zarządzanie wolną pamięcią

System utrzymuje listę wolnych przestrzeni **free-space list**, aby śledzić które bloki są wolne, a które nie. Niekoniecznie jest to rzeczywiście lista. Zwykle jest to **bitmapa** lub **wektor bitów** (0-wolny blok, 1-zajęty). W tym rozwiązaniu można też łatwo znaleźć grupe przylegających wolnych bloków.

Innym rozwiązaniem jest implementacja listy łączonej wolnych bloków. Wtedy oszczędzamy miejsce nie musząc trzymać całego wektora bitów w pamięci, a jedynie potrzebujemy początku listy. Modyfikacją tego rozwiązania jest grupowanie - zamiast trzymać każdy blok, trzymamy adres pierwszego z 'n' wolnych bloków.

Kolejnym rozwiązaniem są **Space Maps** implementowane w systemie **ZFS**. Jest to efektywne rozwiązanie dla systemów z dużą ilością operacji I/O np. gdy zwalniamy 1GB z 1TB dysku, wektor bitowy wolnych bloków będzie musiał być zmodyfikowany w wielu miejscach. ZFS dzieli pamięć dyskową na "płyty" **metaslabs**, a dla każdej płyty jest stworzona mapa, która nadzoruje aktywność na płycie. (Dość skomplikowane, nie ma co się wgłębiać)

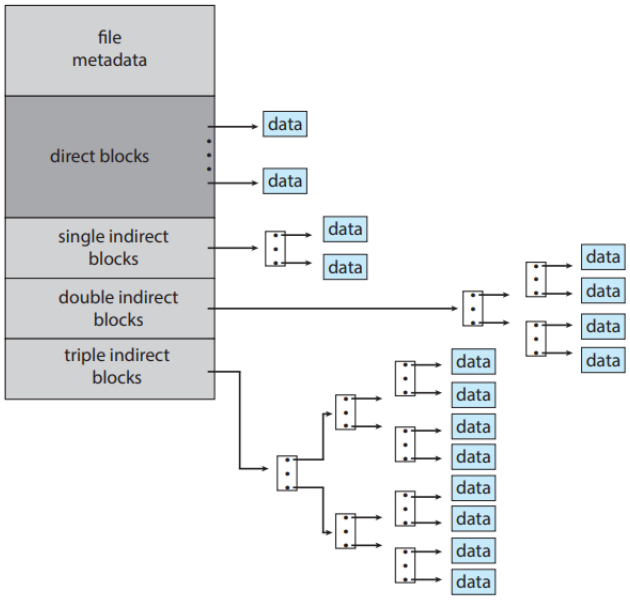

Rysunek 20: UNIX'owy inode – zmodyfikowany blok indeksowy

13.7 Efektywnośc i wydajność

Pamięć nieulotna (dyski) jest najwolniejszym komponentem w pamięci komputera przez co stosuje się różne techniki ograniczające te utrudnienia.

- **Pamięć podręczna bloków dyskowych (disk cache)** – Przechowuje najczęściej używane bloki dyskowe przez co zmniejsza liczbę operacji dyskowych.
- **Zapis asynchroniczny** – Dane są zapisywane na dysku z wykorzystaniem pamięci podręcznej "w tle".
- **Free-behind i read-ahead** – Zwalnianie strony z bufora od razu gdy następna strona jest zażądana, ponieważ prawdopodonbnie raz użyta strona nie będzie zaraz znowu użyta. Wczytywanie zamówionej strony razem z kilkoma następnymi zakładając, że prawdopodobnie będą potrzebne.

Używane są bufory bloków dyskowych, które pośredniczą w przesyłaniu danych między dyskiem, a pamięcią główną. W zależności od tego czy pamięć stron jest przechowywana w taki sam sposób jak bloki dyskowe możemy mieć systemy z jednolitą lub niejednolitą pamięcią podręczną I/O.

- Brak jednolitej pamięci podręcznej – Pamięć podręczna stron (page cache) przechowuje strony w inny sposób niż bloki dyskowe i operacje I/O na pamięci zmapowanej nie mogą używać wspólnego bufora z dyskowymi operacjami I/O read() i write().
- Jednolita pamięć podręczna – Możemy trzymać we wspólnym buforze bloki pamięci do stron pamięci wirtualnej i kopii bloków dyskowych.

13.8 Organizacja dysku

Pierwszy rekord startowy dysku to **Master Boot Record (MBR)**. Czyta on tablicę partycji i inicjuje ładowanie systemu. Pozostała pamięć urządzenia jest podzielona logicznie na partycje, wolumeny, tomy itp.

14 Cheatsheet funkcji i struktur

int fprintf(FILE restrict*stream, const char *restrict format, ..)

void perror(const char *s) - pisze na stderr

int fscanf(FILE restrict*stream, const char *restrict format, ..) – zczytuje ze strumienia według formatu. Zwraca liczbe przypisanych inputów jeśli sukces, EOF jeśli input się kończy przed pierwszą konwersją i bez błędu, EOF i errno jeśli błąd.

char * fgets(char *restrict s, int n, FILE *restrict stream) – zczytuje n-1 bajtów albo do wystąpienia newline i wpisuje jako następny bajt nullbyte. Gdy sukces zwraca s, jeśli strumień jest na EOF ustawia wskaźnik EOF strumienia i zwraca NULL, jeśli błąd ustawia errno i zwraca NULL.

void exit(int status) – kończy proces (EXIT_FAILURE, EXIT_SUCCESS)

int atoi(const char *str) – string to integer. Gdy się nie uda zwraca 0, albo tyle ile da radę. „56test” zwroci 56.

long strotol(const char *restrict str, char **restrict endptr, int base) – Tak samo jak atoi tylko zdefiniowane lepiej I ma endptr (może być null tylko rzutować trzeba np. (char**)NULL) oraz podstawe base.

int getopt(argc, char * const argv[], const char *optstring) – command line parser. Zwraca następną znalezioną opcje gdy znajdzie, ':' gdy znajdzie brakujący wymagany argument, '?' gdy znajdzie opcje nie uwzględnioną w opstringu, -1 gdy wszystko sparsuje.
opstring="t:n::" //t wymagane n opcjonalne
extern char *optarg – przyjmuje wartość aktualnie znalezionego argumentu
extern int opterr – jeśli !=0 będzie wyrzucać błędy na stderr, jeśli ustawimy na 0 getopt będzie tylko zwracać '?' przy błędzie.
extern int optind – indeks następnego elementu argv[] do przetworzenia
extern int optopt – znak opcji, który wywołał error

extern char **environ - trzeba zadeklarować żeby się dostać. Zmienianie: environ[5]

char* getenv(const char *name) – jesli sukces, zwraca pointer do stringa z wartością zmiennej. Jeśli błąd - zwraca NULL

int putenv(char *string) – ustawia zmienną środowiskową: "name=value". Jeśli sukces zwraca 0, jeśli błąd - zwraca !=0 i ustawia errno.

int setenv(const char *envname, const char *enval, int overwrite – działa jak putenv tylko podajemy w dwóch argumentach nazwe i wartość. Jeśli overwrite = 0 - nadpisze, overwrite !=0 - nie nadpisze. Jeśli sukces zwraca 0, jeśli błąd - zwraca -1 i ustawia errno.

DIR *opendir(const char *dirname) – otwiera strumień katalogu (dla aktualnego "."). Jeśli sukces, zwraca wskaźnik do strumienia, jeśli błąd zwraca NULL i ustawia errno.

DIR *fdopendir(int fd) – działa jak opendir, ale przyjmuje file descriptor.

int closedir(DIR *dirp) – Zamyka strumień. Sukces: 0, Błąd: -1 i errno.

struct dirent * readdir(DIR *dirp) – czyta po kolei struktury **dirent** dla plików w katalogu. Nie zwraca dla plików z pustymi nazwami. Sukces: wskaźnik do struktury lub NULL gdy koniec, ale nie ustawia errno, Błąd: NULL i errno

struct dirent – Zawiera: ino_t d_ino - Numer seryjny pliku, char d_name[] - nazwa pliku.

struct stat – struktura na dokładne informacje o pliku. Wszystkie pola w man 2 lstat. mode_t st_mode - pole opisujące typ i tryb pliku. Makra do odczytywania st_mode w man 7 inode. Główne: S_ISREG, S_ISDIR, S_ISLINK. W stat nie ma informacji o nazwie pliku! - plik sam w sobie nie wie jaką ma nazwe, przecież może mieć kilka nazw.

int stat(const char *restrict path, struct stat *restrict buf – wpisuje informacje o pliku do struktury stat. Sukces: 0, Błąd: -1 i errno.

int lstat(const char *restrict path, struct stat *restrict buf) – działa jak stat, ale dla symlinków daje info o symlinkach a nie o pliku do którego się odnoszą.

int fstat(int fd, struct stat *buf) – działa jak stat, ale przyjmuje deskryptor pliku.

char *getcwd(char *buf, size_t size) – wstawia ścieżke current working directory do miejsca wskazanego przez buf, size: długość tablicy wskazywanej przez buf (gdy NULL unspecified zachowanie). Sukces: zwraca buf, Błąd: NULL i errno.

int chdir(const char *path) – ustawia CWD na wartość wskazywaną przez path. Sukces 0, Błąd: -1 i errno.

int nftw(const char *path, int (*fn)(const char*, const struct stat *, int, struct FTW *), int fd_limit, int flags) – przechodzi w dół drzewa plików. Argumenty:

- path – ścieżka od której zaczynamy iść w dół

- fn – wskaźnik do funkcji opisanej przez nas w powyższy sposób. nftw wykonuje ją na każdym pliku i przypisuje po kolei: ścieżkę pliku, strukture stat o pliku, int type do którego mamy stałe - mówi nam o typie pliku, strukture FTW - chyba flaga jaką mamy ustawioną.
- fd_limit – maksymalna liczba użytych deskryptorów plików
- flags – użyte flagi: FTW_PHYS - nie wchodzi w głąb symlinków.

Koniecznie #define _XOPEN_SOURCE 500 ,przed wszystkim innym, bez tego nie znajdzie nftw. Zwraca: 0 - drzewo się skończyło, -1 i errno - błąd, coś innego - nasze fn zwróciła !=0 wtedy zwraca te wartość.

int ftw(const char *path, int (*fn)(const char*, const struct stat *ptr, int flag), int ndirs) –

FILE *fopen(const char* restrict path, const char* restrict mode) - otwiera strumień. tryb: r-readonly, w-obcina do zero albo tworzy nowy writeonly, a-append otwiera w punkcie EOF, r+ - read and write, w+ obcina do zera i write and read, a+- read and append. Sukces: zwraca pointer na obiekt strumienia, Błąd: null i errno.

int fclose(FILE *stream) – Zamyka strumień. Sukces: 0, Błąd: EOF i errno.

int fseek(FILES *stream, long offset, int whence) - Przesuwa wskaźnik strumienia o offset od pozycji SEEK_SET - początkowa, SEEK_CUR - aktualna, SEEK_END - eof. Sukces: 0, Bład: -1 i errno.

int unlink(const char *path) – usuwa directory entry powiązane z plikiem (czyli w sumie chyba plik). Sukces: 0, Błąd: -1 i errno. UWAGA: errno ma wartość ENOENT gdy się nie udało bo plik nie istniał.

mode_t umask(mode_t cmask) – ustawia aktualną umaske (umaska jest w systemie ósemkowym). Ex. umask(permissions&0777). Zwraca starą umaske.

int open(const char *pathname, int oflag, mode_t mode) – niskopoziomowa funkcja do otwierania istniejącego lub nieistniejącego pliku. Argumenty:

- pathname - ścieżka do pliku

- oflag - suma logiczna flag (pełna lista w manie)
- mode - prawa przy tworzeniu pliku (RWX-RWX-RWX). Pamiętając że efektywnie i tak będzie to zależało od umaski: mode & umask. Pierwsza trójka bitów to sticky bity (SUID-SGID-SVTX). Jeśli nie ustawione to dziedziczy po procesie wywołującym.
    1. SUID – Jeśli ustawiony to plik otwierany jest z uprawnieniami użytkownika (UID użytkownika staje się tymczasowo UID'em właściciela), który jest właścicielem pliku (np. passwd musi mieć ten bit bo innaczej użytkownicy nie mogliby edytować swojego hasła)
    2. SGID – Działa podobnie do SUID tylko odnosi się do grupy. Otwieramy plik tak jakbyśmy byli członkami grupy do której plik należy.
    3. SVTX – Tak zwany Sticky Bit. Oznacza, że na plik (albo katalog) może być usunięty lub może mu być zmieniona nazwa tylko przez właściciela pliku (albo roota oczywiście). Czyli nawet mając wszystkie uprawnienia do pliku, inny użytkownik nie może usunąć pliku innemu użytkownikowi. Przydatne np. dla katalogu /tmp aby użytkownicy nie usuwali sobie nawzajem plików.

Sukces: otwiera plik zwraca najmniejszy, nieużywany, nieujemny deskryptor pliku. Porażka: Zwraca -1, nie tworzy żadnego pliku i ustawia errno.

ssize_t read(int fd, void *buf, size_t nbyte) – funkcja próbuje przeczytać *nbyte* bajtów z pliku powiązanego z deskryptorem pliku *fd* do bufora *buf*. Zachowanie dla kilku readów z tego samego pipe, FIFO albo terminala jest niezdefiniowane.

int kill(pid_t pid, int sig) – funkcja wysyła sygnał **sig>0** do procesu. W zależności od pid funkcja wysyła sygnał do:

- pid>0 – Do procesu z danym PID
- pid==0 – Do wszystkich procesów które należą do grupy procesów wysyłającego procesu. Zwykle do wszystkich dzieci i mozliwe kilku przodków.
- pid==-1 – Do wszystkich procesów w systemie (oprócz **init**)
- pid<-1 – Do wszystkich procesów, które należą do grupy procesów **pgid==-pid**

Dla sig==0, sygnał nie jest wysyłany, ale standardowe sprawdzanie błędów jest wykonywane. Sukces: zwraca 0. Porażka: zwraca -1 i ustawia errno.

int sigaction(int sig, const struct sigaction *restrict act, struct sigaction *restrict oact) – funkcja służy do konfigurowania nowej procedury obsługi sygnału lub/i sprawdzenia starej.

- sig – numer sygnału, którego osbługę chcemy zmienić
- act – wskaźnik do struktury zawierającej nową konfiguracje obsługi sygnału.
- oact – wskaźnik do struktury do której zapisana zostanie stara procedura.

Sukces: 0. Porażka: -1 i errno.

struct sigaction – struktura zawierająca konfiguracje obsługi sygnału, zawiera:

- void(*sa_handler) (int) sa_handler – wskaźnik do funkcji obsługującej sygnał: funkcja musi przyjmować int i zwracać void. Istnieją makra SIG_DFL (domyślnie) i SIG_IGN (ignoruj sygnał).
- sigset_t sa_mask – maska sygnałów które będą blokowane podczas obsługi sygnałów
- int sa_flags – flagi zmieniające zachowanie sygnałów (pełna lista man 3p sigaction)
- void(*) (int, siginfo_t *, void *) sa_sigaction – kolejny wskaźnik do funkcji obsługującej sygnał ale bardziej rozbudowana - powinno się używać tylko jednej z dwóch.

Sukces: 0. Porażka -1 i errno.

int sigemptyset(sigset_t *set) – inicjalizuje pusty set sygnałów w miejsce wskazane przez *set*. Sukces: 0. Porażka: -1 i errno.

int sigaddset(sigset_t *set, int signo) – Dodaje sygnał o numerze *signo* do struktury *set*. Wcześniej należy zainicjować pusty set funkcją powyżej. Sukces: 0. Porażka: -1 i errno.

int sigprocmask(int how, const sigset_t *restrict set, sigset_t restrict oset) – sprawdza i/lub zmienia maskę sygnałów blokowanych.

- how – ustala w jaki sposób zmieniamy maskę, musimy wybrać jedną z możliwości:
  1. SIG_BLOCK – nowa maska będzie sumą aktualnego i nowego zestawu (setu)
  2. SIG_SETMASK – nowa maska zastąpi starą
  3. SIG_UNBLOCK – nowa maska będzie częścią wspólną aktualnego i nowego zestawu
- set – nowy set sygnałów, jeśli null to możemy w ten sposób sprawdzić aktualnie blokowane sygnały
- oset – miejsce gdzie zapiszemy starą maske

Jeśli są jakieś oczekujące niezablokowane sygnały po użyciu funkcji, przynajmniej jeden powinien został dostarczony zanim funkcja zwróci wartość.

Sukces: 0. Porażka: -1 i errno.

pid_t wait(int *stat_loc) – funkcja wait służy do uzyskiwania informacji od procesów dzieci - wszystkich. Przy wywołaniu wątek blokuje się dopóki nie uzyska informacji o zakończeniu procesu dziecka, lub nie dostanie sygnału który każe mu zrobić coś innego, może również wystąpić błąd. Jeśli wystąpi zakończenie dwóch lub więcej procesów dzieci, kolejność w jakim proces rodzic otrzyma ich status jest niezdefiniowany.

Parametr *stat_loc*, jeśli nie jest ustawiony na *NULL* i jeśli funkcja *wait()* zwróci wartość procesu dziecka to w to miejsce zapiszę się wartość 0 jeśli proces dziecko:

- Zwrócił 0 w *main()*
- Wywołał *exit()* z parametrem 0
- Zakończył się bo wszystkie wątki się zakończyły

Pomimo to wartość ta może być interpretowana makrami mówiące nam co się stało z procesem dzieckiem. Jeśli wartość danego makra jest niezerowa to:

- WIFEXITED – proces zakończył się standardowo

- WEXITSTATUS – Jeśli WIFEXITED niezerowe to można odczytać status z jakim się zakończył
- WIFSIGNALED – Jeśli proces zakończył się z powodu nieprzechwyconego sygnału
- WTERMSIG – Jeśli WIFSIGNALED niezerowe to możemy odczytać numer sygnału
- WIFSTOPPED – Jeśli proces jest aktualnie zatrzymany
- WSTOPSIG – Jeśli WIFSTOPPED niezerowe to możemy odczytać numer sygnału stopu
- WIFCONTINUED – Jeśli status został zwrócony dla procesu ktore kontynuowało z *job control stop*

Jeśli proces rodzic zakończy bez czekania, dzieci otrzymają nowego rodzica (*init*).

Sukces: zwraca PID dziecka. Dostarczono sygnał przerywający: zwraca -1 i errno.

pid_t waitpid(pid_t pid, int *stat_loc, int options) – działa jak *wait()* z kilkoma różnicami.

Czeka na konkretny proces lub grupę procesów, to na jaki proces czeka opisuje **pid** z zasadami takimi jak w funkcji *kill()*.

options to bitowa suma flag, która mówi nam w jaki sposób ma zachować się funkcja. Flagi:

- WCONTINUED – funkcja powinna obsłużyć status dowolnego kontynuowanego procesu, który nie był raportowany odkąd kontynuował po "job control stop".
- WNOHANG – Funkcja nie blokuje wątku i nie czeka, jeśli od razu nie ma do odebrania statusu jakiegoś procesu.
- WUNTRACED – Status dowolnego procesu (zdefiniowanego przez *pid* oczywiście) który został zatrzymany i którego status nie został odebrany odkąd się zatrzymał również powinien zostać odebrany.

Sukces: zwraca PID dziecka. Flaga WNOHANG ustawiona i brak (chwilowy) dzieci do odebrania: zwraca 0. Błąd lub dostarczono sygnał przerywający: zwraca -1 i errno.

unsigned sleep(unsigned seconds) – każe wątkowi czekać daną liczbę sekund, w przypadku przerwania przerwania sygnałem zwraca liczbę "niedospanych sekund", w przeciwnym wypadku 0.

void memset(void *s, int c, size_t n) – kopiuje c do pierwszych n bajtów obiektu wskazanego przez s. Standardowo czyścimy nią pamięć np. struktury sigaction: *memset(&obiekt, 0, sizeof(struct sigaction))*.

unsigned alarm(unsigned seconds) – funkcja generuje SIGALARM do procesu po upłynięciu danej liczby sekund. Jeśli uruchomiona w trakcie działania innego alarm() zwraca pozostałą liczbę sekund do wygenerowania sygnału. Jeśli jest jedynym wywołaniem zwraca 0.

int pthread_create(pthread_t *restric thread, constr pthread_attr_t *restrict attr, void*(*start_routine)(void*), void *restrict arg) – funkcja generalnie tworzy nowy wątek, ma dość skomplikowaną budowę argumentów, więc należy ją opisać po kolei:

- thread – wskaźnik do struktury, gdzie zapisze się TID (thread ID)
- attr – wskaźnik do struktury z atrubutami dla wątku, strukturę trzeba najpierw zaiinicjować (do przeczytania man 3p pthread_attr_init()), a potem warto ją zniszczyć. NULL oznacza domyślne ustawienia. Na początku będziemy używać jedynie podstawowych opcji.

  Najczęstsza funkcja ustawiania – pthread_attr_setdetachstate(pthread_attr_t *atr, int detachstate) , ustawia nam stan odłączenia nowo tworzonych wątków. Gdzie detachstate to makro **PTHREAD_CREATE_JOINABLE** (będziemy czekać na wątek) i **PTHREAD_CREATE_DETACHED** (nie będziemy czekać).
- start_routine – funkcja wykonywana przez wątek, musi mieć sygnature: przyjmuje wskaźnik na void, zwraca wskaźnik na void.
- arg – argument przekazywany do funkcji wątku.

Jeśli sukces: zwraca 0. Porażka: "error number".

int pthread_join(pthread_t thread, void **value_ptr) – funkcja zawiesza działanie wątku, dopóki wątek dany w *thread* się nie zakończy, chyba że już to zrobił.

int pthread_detach(pthread_t thread) – odłącza dany wątek i nie mamy już prawa wykonywać joina.

int mkfifo(const char *path, mode_t mode) – funkcja tworzy nowy plik FIFO w podanej ścieżce. Tryb dostępu jest określany przez *mode*. Jeśli ścieżka prowadzi do symlinka lub FIFO istnieje funkcja się nie powodzi, a errno ma wartość **EEXIST**. Jeśli sukces: zwraca 0. Porażka: -1, FIFO nie jest tworzone i errno ustawione.

int pipe(int fildes[2]) – funkcja tworzy łącze nienazwane i zapisuje deskryptor do czytania w fildes[0] i deskryptor do pisania w fildes[1]. Jeśli sukces: zwraca 0. Porażka -1, pipe nie jest tworzony i ustawia errno.

mqd_t mq_open(const char *name, int oflag, mode_t mode, struct mq_attr) – funkcja tworzy połączenie pomiędzy procesem i kolejką komunikatów. Funkcja posiada parametry:

- **name** – wskazanie na napis (c-string) będący nazwą kolejki komunikatów. Ma ona specyficzny format nazwy ścieżkowej. Bardzo ważne żeby zaczynała się od / i nie miała tego znaku nigdzie indziej. Niestosowanie tej reguły jest niezdefiniowane. Poprawną nazwą jest np. */myqueue*.
- **oflag** – tryb tworzenia kolejki tak jak dla plików: O_RDONLY, O_WRONLY, O_RDWR, O_CREAT, O_EXCL, O_NONBLOCK.
- **mode** – prawa dostępu do kolejki: r i w.
- **attr** – wskazanie do struktury atrybutów kolejki.

Jeśli sukces: zwraca deskryptor kolejki. Porażka: (mqd_t) -1 i ustawia errno.

int mq_close(mqd_t mqdes) – usuwa połączenie powiędzy deskryptorem kolejki, a kolejką. Jeśli istniała subskrypcja na powiadomienie z tą kolejką i procesem wywołującym to jest ona usuwana. Jeśli sukces: zwraca 0. Porażka: -1 i ustawia errno.

int mq_unlink(const char *name) – usuwa kolejke komunikatów o podanej nazwie nawet jeśli jakieś procesy jeszcze mają ją otwartą. Jeśli sukces: zwraca 0. Porażka: -1 i ustawia errno.

int mq_send(mqd_t mqdes, const char *msg_ptr, size_t msg_len, unsigned msg_prio) – funkcja dodaje komunikat do kolejki komunikatów. Jeśli kolejka jest pełna, a flaga NON_BLOCK nieustawiona to funkcja się zablokuje, az nie znajdzie się miejsce lub nie przerwie jej sygnał. Jeśli więcej niż jeden wątek czeka na wysłanie i system wspiera Priority Scheduling to pierwszy jest ten, który najdłużej czekał. W trybie nieblokującym zwróci błąd.

- **mqdes** – deskryptor kolejki
- **msg_ptr** – komunikat
- **msg_len** – długość komunikatu
- **msg_prio** – priorytet

Jeśli sukces: zwraca 0. Porażka: -1 i ustawia errno.

int mq_timedsend(mqd_t mqdes, const char *msg_ptr, size_t msg_len, unsigned msg_prio, const struct timespec *abstime) – Działa dokładnie tak jak *mq_send()*, ale dodatkowo podajemy *abstime* – czyli moment, w którym zablokowana funkcja zwróci błąd **ETIMEDOUT**, jeśli nie uda się do tego czasu zapisać komunikatu. Bardzo ważne: to nie jest czas po którym funkcja wyjdzie tylko timestamp, w którym to się stanie. Jeśli sukces: zwraca 0. Porażka: -1 i ustawia errno.

ssize_t mq_receive(mqd_t mqdes, char *msg_ptr, size_t msg_len, unsigned *msg_prio) – Odbiera najstarszą spośród wiadomości o najwyższym priorytecie z kolejki z deskryptorem *mqdes*. Mechanizm blokowania działa tak samo jak przy zapisywaniu komunikatu.

- **mqdes** – deskryptor kolejki
- **msg_ptr** – wskaźnik do miejsca gdzie komunikat zostanie skopiowany
- **msg_len** – długość odbieranego komunikatu, jeśli mniejsza niż *mq_msgsize* to funkcja zwróci błąd.
- **msg_prio** – jeśli nie jest NULL, priorytet wiadomości zostanie zapisany do miejsca wskazanego przez wskaźnik

Jeśli sukces: zwraca długość odebranej wiadomości i usuwa komunikat z kolejki. Porażka: -1 i ustawia errno.

ssize_t mq_timedreceive(mqd_t mqdes, char *restrict msg_ptr, size_t msg_len, unsigned *restrict msg_prio, const struct timespec *restrict abstime) – funkcja analogiczna do *mq_receive()* w wersji timed (patrz *mq_send()* i *mq_timedsend()*).

int mq_getattr(mqd_t mqdes, struct mq_attr *attr) – funkcja pobiera atrybuty kolejki komunikatów o deskryptorze *mqdes* i zapisuje w miejsce wskaźnika *attr*. Jeśli sukces: zwraca 0. Porażka: -1 i ustawia errno.

int mq_setattr(mqd_t mqdes, const struct mq_attr *restrict newattr, struct mq_attr *restrict oldattr) – funkcja ustawia atrybuty kolejki komunikatów o deskryptorze *mqdes* z miejsca wskazanego przez *newattr* wstawiając starą strukturę do miejsca wskazanego przez *oldattr* UWAGA: nowa struktura może zmienić tylko pole *mq_flags* czyli tryb blokowania, zmiana któregokolwiek innego pola struktury zostanie zigorowana. Jeśli sukces: zwraca 0. Porażka: -1 i ustawia errno.

int mq_notify(mqd_t mqdes, const struct sigevent *notification) – funkcja służy do ustawienia powiadamiania procesu w momencie gdy kolejka komunikatów była pusta i coś się w niej znajdzie (nie za każdą wiadomością!). Jeśli **notification** jest NULL, wtedy anulujemy subskrypcje i inny proces może ją zrobić. Opcja powiadamiania: sygnał, wątek lub nic. Więcej o strukturze sigevent w *man 7 sigevent*. Jeśli sukces: zwraca 0. Porażka: -1 i ustawia errno.

struct sigevent – Struktura służąca do powiadamiania dla mechanizmów asynchronicznych, szczegóły w man 7 sigevent. Jej pola to:

- **int sigev_notify** – Metoda notyfikacji: SIGEV_NONE, SIGEV_SIGNAL, SIGEV_THREAD.
- **int sigev_signo** – Sygnał jakim ma być powiadamiany wątek w przypadku SIGEV_SIGNAL.
- **union sigval sigev_value** – Dane przekazywane do wątku w postaci unii o polach: **int sival_int** i **void *sival_ptr**.
- **void (*sigev_notify_function) (union sigval)** – Funkcja używana przy powiadamianiu wątkiem (SIGEV_THREAD).
- **void *sigev_notify_attributes** – Atrybuty dla funkcji przy powiadamianiu wątkiem (SIGEV_THREAD).

W przypadku metody powiadamiania sygnałem, SIGEV_SIGNAL, jeśli sygnał został przechwycony przez handler zarejestrowany z flagą SA_SIGINFO (man 3p sigaction), wtedy jako drugi argument dostaje on strukturę **siginfo_t** z następującymi wartościami na konkretnych polach:

- *si_code* – pole zależne od API dostarczającego powiadomienie
- *si_signo* – pole ustawione na numer sygnału
- *si_value* – zawiera to co wskazane w polu *sigev_value*

int shm_open(...)

void *mmap(...)

int ftruncate(...)

int munmap(...)

int socket(int domain, int type, int protocol) – funkcja powinna uytworzyć niepowiązany socket (gniazdo) związane z konkretną rodziną protokołów i zwrócić deskryptor pliku, który może być używany do wywoływania funkcji na gnieździe.

- *domain* – argument określa "communication domain" czyli określenie z jakiej rodziny protokołów będziemy korzystać. Dla Unixa najczęściej będziemy używać: **AF_UNIX**(lub synonim **AF_LOCAL**) – komunikacja lokalna wewnątrz systemu, lub **AF_INET** – określa rodzinę protokołów IPv4. Można również spotkać wersję z prefixami **PF_**. Każda rodzina protokołów jest powiązana z jedną rodziną adresowania, dlatego istnieją powiązania symboliczne i nie ma znaczenia czy użyjemy wersji AF_... czy PF_... . np. AF_INET PF_INET.
- *type* – typ gniazda, do wyboru: **SOCK_STREAM**, **SOCK_DGRAM** i **SOCK_SEQPACKET**. Przykładowo SOCK_DGRAM udostępnia datagramy używane przez protokół UDP.
- *protocol* – jeśli zostawimy 0, to zostanie przypisany domyślny protokół dla tej rodziny adresów.

Jeśli sukces: zwraca deskryptor pliku. Porażka: -1 i ustawia errno.

int bind(int socket, const struct sockaddr *address, socklen_t address_len) – funkcja przypisuje lokalny adres gniazda, dla gniazda wskazanego przez deskryptor, które aktualnie nie ma żadnego powiązania z żadnym adresem.

- *socket* – deskryptor pliku powiązany z gniazdem.
- *address* – wskaźnik na strukturę **sockaddr** zawierającą adres do którego ma być przypisane gniazdo. To jest dość skomplikowane i dziwne, bo te struktury zwykle nie są typu *sockaddr*, a jedynie pokrywają te strukture bazową, więc trzeba je rzutować. Opis bazowej struktury i najczęściej używanych poniżej.
- *address_len* - określa długość struktury wskazywanej przez *address*.

Jeśli numer portu odczytany z struktury *address* to system wybiera automatycznie **port efemeryczny**, czyli po prostu automatycznie przydziela mu numer portu.

Jeżeli rodzina adresowania to **AF_UNIX** i ścieżka do pliku w adresie jest symlinkiem to funkcja się nie powiedzie.

Jeśli sukces: zwraca 0. Porażka: -1 i ustawia errno.

struct sockaddr – ogólna struyktura adresowa, musi zawierać pola:

- *sa_family_t* ***sa_family*** – rodzina adresowa. Używamy makr np. AF_UNIX.
- *char* ***sa_data_t[]*** – adres właściwy dla protokołu, zmienna długość.

struct sockaddr_in – struktura adresowa dla IPv4, musi zawierać pola:

- *sa_family_t* ***sin_family*** – koniecznie == AF_INET.
- *in_port_t* ***sin_port*** – 16 bajtowy numer portu (uint16_t)
- *struct in_addr* ***sin_addr*** – struktura zawierająca tylko jedno pole: 32 bajtowy adres IPv4 (uint32_t)

Ważne: sin_port i sin_addr są w porządku sieciowym (big-endian).

struct sockaddr_un – struktura adresowa dla domeny UNIX, musi zawierać pola:

- *sa_family_t* ***sun_family*** – koniecznie == AF_UNIX lub AF_LOCAL.
- *char* ***sun_path[]*** – nazwa ścieżkowa, w POSIX długość nieokreślona, zwykle 92-108. Jest to ścieżka bewzględna!

int connect(int socket, const struct sockaddr *address, socklen_t address_len) – funkcja próbuje nawiązać połączenie na gnieździe w trybie połączeniowym lub w przypadku gniazd w trybie bezpołączeniowym ustawia lub resetuje adres "partnera". (peer).

- *socket* – deskryptor pliku powiązany z gniazdem.
- *address* – wskaźnik na strukturę **sockaddr** zawierającą adres hosta z którym chcemy nawiązać połączenie.
- *address_len* - określa długość struktury wskazywanej przez *address*.

Jeśli gniazdo nie jest wcześniej zaadresowane to funkcja automatycznie go zaadresuje, (nie działa rodzinie adresowej AF_UNIX). Jeśli sukces: zwraca 0. Porażka: -1 i ustawia errno.

int listen(int socket, int backlog) – funkcja oznacza gniazdo o deskryptorze *socket* w trybie połączeniowym jako akceptujące połączenia – rozpoczyna nasłuch. Parametr *backlog* określa limit oczekujących połączeń w kolejce oczekujących dla gniazda. Jeśli sukces: zwraca 0. Porażka: -1 i ustawia errno.

int accept(int socket, struct sockaddr *restrict address, socklen_t *restrict address_len) – funkcja wybiera pierwsze połączenie w kolejce oczekujących, tworzy nowe gniazdo o takim samym typie protokołu i rodzinie adresowej jak wybrane gniazdo i alokuje nowy deskryptor pliku dla tego gniazda.

- *socket* – określa deskryptor gniazda, które słuchało funkcją *listen()* i właśnie otrzymało połącznenie.
- *address* – wskaźnik na strukturę **sockaddr**, gdzie zapisze się adres podłączającego się socketa. Może być NULL.
- *address_len* - wskaźnik na **socklen_t** gdzie zapisze się długość struktury adresowej. Może być NULL.

Jeśli sukces: zwraca deskryptor pliku powiązany z zaakceptowanym gniazdem. Porażka: -1 i ustawia errno.

int pselect(int nfds, fd_set *restrict readfds, fd_set *restrict writefds, fd_set *restrict errorfds, const struct timespec *restrict timeout, const sigset_t *restrict sigmask) – funkcja powinna deskryptory podane w formie zestawów w polach: readfds, writefds i errordfs aby sprawdzić czy któreś z nich są gotowe do odczytu, do zapisu, albo mają oczekujące wyjątki (dokładnie w tej kolejności – każdy zestaw badamy inaczej).

nfds określa zakres deskryptorów plików do sprawdzenia (sprawdza się od 0 do nfds-1 czy jakoś tak). W przypadku powodzenia, funkcja modyfikuje obiekty wskazywane przez wskaźniki w parametrach pokazując, który deskryptor jest gotowy do czytanie, pisania, obsługi błędów.

Funkcja zastąpi aktualną maskę, maskami podanymi w parametrze *sigmask* (jeśli nie NULL). Można ustawić również max timeout, albo zostawić NULL.

Funkcja zwróci całkowitą liczbe deskryptorów. Jeśli żaden deskryptor nie jest gotowy to funkcja się zablokuje.

int fcntl(int fildes, int cmd, ...) – funkcja wykonuje operacje na otwartych plikach. *fildes* to deskryptor plikum, a *cmd* to flagi. Przykładowo: F_GETFL zwróci nam aktualne flagi pliku, a F_SETFL ustawi nowe flagi. Funkckja zwraca różne wartości, w zależności od podanych flag *cmd*.

void freeaddrinfo(struct addrinfo *ai) – funkcja zwalnia struktury addrinfo zwrcane przez funkcje getaddrinfo().

int getaddrinfo(const char *restrict nodename, const char *restrict servname, const struct addrinfo *restrict hints, struct addrinfo **restrict res) – funkcja tłumaczy nazwy serwisów na adresy gniazd. Dość obszerne narzędzie do np. znajdywania adresów ip.

- *nodename* – jeśli nie jest nullem, nazwa lub adres, np : google.com
- *servname* – jeśli nie jest nullem, to mamy tutaj pożądaną usługę np. dla AF_INET będzie to numer portu.
- *hints* - jeśli nie jest nullem, odnosi się do struktury z ustawieniami.
- *res* - wskaźnik do struktury z wypełnionymi polami określającymi adres gniazda i informacje potrzebne do utworzenia gniazda.

Zwraca błąd, który możemy odczytać funkcją gar_strerror

const char *gai_strerror(int ecode) – Pozwala otrzymać wiadomość błędu opisujący błąd z funkcji getaddrinfo().

ssize_t sendto(int socket, const void *message, size_t length, int flags, const struct sockaddr *dest_addr, socklen_t dest_len) – funkcja wysyła wiadomość do socketa w trybie połączeniowym lub bezpołączeniowym.

- *socket* – socket, z którego wysyłamy wiadomość.
- *message* – wskaźnik do wiadomości.
- *length* – długość wiadomości w bajtach
- *flags* – flagi(narazie zostawiamy 0)
- *dest_addr* – struktura adresowa celu
- *dest_len* – długość struktury